

OpenClaw DeepResearch 引用一致性评测证据材料

实验材料整理

2026-06-08

目录

1 材料说明

本文档汇总 OpenClaw DeepResearch 引用一致性实验的证据材料，包括：五个 case 的运行输入与输出、两张运行截图位置、以及两个具体 claim-level 引用错误的原文对照分析。运行记录选自 runs/pre_refchecker_repair/；其中 C1-C4 使用 R1，C5 的 R1 缺少 ORIGINAL_REPORT marker，因此使用 C5 R2 作为完整记录。


截图说明：用户提供的微信 Claw 截图与 agent 后台 JSONL 运行截图已保存至 evidence_materials/assets/，并作为运行环境证据纳入本文档。

2 五个 Case 的运行记录索引

Case	Run	输入 prompt	输出 raw	字符数	输出 marker 计数
C1	R1	runs/pre_refchecker_repair/C1/R1/refchecker_repair/prompt.md	runs/pre_refchecker_repair/C1/R1/refchecker_repair/output.raw.txt	3687 / 10445	{'ORIGINAL_REPORT': 1, 'REFCHECKER_REPAIR_LOG': 1, 'REPAIRED_REPORT': 1, 'RUN_SUMMARY': 1}
C2	R1	runs/pre_refchecker_repair/C2/R1/refchecker_repair/prompt.md	runs/pre_refchecker_repair/C2/R1/refchecker_repair/output.raw.txt	3938 / 9859	{'ORIGINAL_REPORT': 1, 'REFCHECKER_REPAIR_LOG': 1, 'REPAIRED_REPORT': 1, 'RUN_SUMMARY': 1}
C3	R1	runs/pre_refchecker_repair/C3/R1/refchecker_repair/prompt.md	runs/pre_refchecker_repair/C3/R1/refchecker_repair/output.raw.txt	3948 / 12098	{'ORIGINAL_REPORT': 1, 'REFCHECKER_REPAIR_LOG': 1, 'REPAIRED_REPORT': 1, 'RUN_SUMMARY': 1}
C4	R1	runs/pre_refchecker_repair/C4/R1/refchecker_repair/prompt.md	runs/pre_refchecker_repair/C4/R1/refchecker_repair/output.raw.txt	3803 / 9847	{'ORIGINAL_REPORT': 1, 'REFCHECKER_REPAIR_LOG': 1, 'REPAIRED_REPORT': 1, 'RUN_SUMMARY': 1}
C5	R2	runs/pre_refchecker_repair/C5/R2/refchecker_repair/prompt.md	runs/pre_refchecker_repair/C5/R2/refchecker_repair/output.raw.txt	3763 / 10430	{'ORIGINAL_REPORT': 1, 'REFCHECKER_REPAIR_LOG': 1, 'REPAIRED_REPORT': 1, 'RUN_SUMMARY': 1}

3 运行截图





```
1 000b099c-e579-4d4b-b9e9-2a0f9fe19007.jsonl
2
3 timestamp:"2026-06-04T19:00:43.129Z", "provider":"deepseek", "modelId":"deepseek-v4-pro"
4 d":"8d5beeb3", "timestamp":"2026-06-04T19:00:43.129Z", "thinkingLevel":"high"
5 timestamp:"1780599643164", "provider":"deepseek", "modelApi":"openai-completions", "modelId":"deepseek-v4-pro", "id":"f45a2872", "parentId":"36596b9
6 timestamp:"2026-06-04T19:00:43.191Z", "message":{"role":"user", "content":[{"type":"text", "text":"你是一名科研助理。你需要完成一份科研报告，并在报告生
7 timestamp:"2026-06-04T19:00:49.997Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"The user wants me to complete a
8 timestamp:"2026-06-04T19:00:50.637Z", "message":{"role":"toolResult", "toolCallId":"call_00_DjWakJjANpWadVQLnL4642", "toolName":"read", "conten
9 timestamp:"2026-06-04T19:00:50.643Z", "message":{"role":"toolResult", "toolCallId":"call_02_w8CdLCJrR0xvFm3c2oYi3448", "toolName":"read", "conten
10 timestamp:"2026-06-04T19:01:07.150Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"The PDFs are binary files and I
11 timestamp:"2026-06-04T19:01:13.999Z", "message":{"role":"toolResult", "toolCallId":"call_00_cuw1STRtfzmDD220k5z5238", "toolName":"read", "conten
12 timestamp:"2026-06-04T19:01:14.001Z", "message":{"role":"toolResult", "toolCallId":"call_01_LQtQDi09Ih3QkkF2xCKM8890", "toolName":"arxiv_downlo
13 timestamp:"2026-06-04T19:01:14.003Z", "message":{"role":"toolResult", "toolCallId":"call_02_Xs81hweckvncKHmCVBod0996", "toolName":"arxiv_downlo
14 timestamp:"2026-06-04T19:01:14.005Z", "message":{"role":"toolResult", "toolCallId":"call_03_wIpdpsR9KjJqcPKsIwM1484", "toolName":"arxiv_downlo
15 timestamp:"2026-06-04T19:01:27.592Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"I've now downloaded the three pr
16 timestamp:"2026-06-04T19:01:38.193Z", "message":{"role":"toolResult", "toolCallId":"call_00_vux7T47HXrGpying65Vv6569", "toolName":"arxiv_search
17 timestamp:"2026-06-04T19:01:38.195Z", "message":{"role":"toolResult", "toolCallId":"call_01_oDv6Nzg0DnbF8zE6bek1442", "toolName":"arxiv_search
18 timestamp:"2026-06-04T19:01:38.197Z", "message":{"role":"toolResult", "toolCallId":"call_02_xWkSsWNB3r6YODMsu0ng1167", "toolName":"arxiv_search
19 timestamp:"2026-06-04T19:01:55.175Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"arXiv API seems to be timing out
20 timestamp:"2026-06-04T19:01:56.861Z", "message":{"role":"toolResult", "toolCallId":"call_00_6b9fIS3kcekWimZusqC4344", "toolName":"web_search", "
21 timestamp:"2026-06-04T19:01:56.865Z", "message":{"role":"toolResult", "toolCallId":"call_01_gdDUzwoyeDfioYYWnbW65319", "toolName":"web_search", "
22 timestamp:"2026-06-04T19:02:12.918Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"I need to find three highly rele
23 timestamp:"2026-06-04T19:02:14.094Z", "message":{"role":"toolResult", "toolCallId":"call_00_NuCajHc4X7gvfIavpyTE6054", "toolName":"web_search", "
24 timestamp:"2026-06-04T19:02:14.096Z", "message":{"role":"toolResult", "toolCallId":"call_01_W0KzVFkiT4kzqVYsFVp8338", "toolName":"web_search", "
25 timestamp:"2026-06-04T19:02:14.100Z", "message":{"role":"toolResult", "toolCallId":"call_02_e8sap0weLeub6twp83o28508", "toolName":"web_search", "
26 timestamp:"2026-06-04T19:02:28.236Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"Let me search for more specific
27 timestamp:"2026-06-04T19:02:29.483Z", "message":{"role":"toolResult", "toolCallId":"call_00_gdCvArYriWxaow0QEqfw6990", "toolName":"web_search", "
28 timestamp:"2026-06-04T19:02:29.486Z", "message":{"role":"toolResult", "toolCallId":"call_01_8ntR0cy0F8pippikL6v2793", "toolName":"web_search", "
29 timestamp:"2026-06-04T19:02:44.676Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"Let me find three highly relevan
30 timestamp:"2026-06-04T19:02:45.914Z", "message":{"role":"toolResult", "toolCallId":"call_00_iFPhnMR84Fnc6As4Z5gZ5825", "toolName":"arxiv_get_ab
31 timestamp:"2026-06-04T19:02:45.918Z", "message":{"role":"toolResult", "toolCallId":"call_01_8j8VPJSz1Jr0MyMsigZ28015", "toolName":"web_search", "
32 timestamp:"2026-06-04T19:02:45.924Z", "message":{"role":"toolResult", "toolCallId":"call_02_M2T3VYiwNSFKchcE6wqP7509", "toolName":"web_search", "
33 timestamp:"2026-06-04T19:03:07.032Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"Let me search for my three addit
34 timestamp:"2026-06-04T19:03:09.004Z", "message":{"role":"toolResult", "toolCallId":"call_00_jmoVA6nq0Wyp5IvoJM6T9398", "toolName":"arxiv_get_ab
35 timestamp:"2026-06-04T19:03:09.007Z", "message":{"role":"toolResult", "toolCallId":"call_01_Y9vSa6yFLue2nru76aac6494", "toolName":"arxiv_get_ab
36 timestamp:"2026-06-04T19:03:09.012Z", "message":{"role":"toolResult", "toolCallId":"call_02_Rifu6agKsqQICMAXL70UA5151", "toolName":"web_search", "
37 timestamp:"2026-06-04T19:03:24.947Z", "message":{"role":"assistant", "content":[{"type":"thinking", "thinking":"Let me find three good papers fo
38 timestamp:"2026-06-04T19:03:26.045Z", "message":{"role":"toolResult", "toolCallId":"call_00_EzE4V8xvASVLMh1URVSg5910", "toolName":"arxiv_search
```

图 2: Agent 后台 JSONL 运行截图。

4 两个失败 Claim 的原文对照分析

4.1 错误样例 1

错误类型: Overclaim / scope inflation

Claim: 工具增强型 LLM agent 在仓库级软件工程任务上显著优于非交互式 LLM prompting, 差距可达数倍至近一个数量级。

引用位置: [A]§1::¶3/[E]§5::T1

原文片段 1: A Self-Improving Coding Agent. / locator:1

“We demonstrate that an agent system, equipped with basic coding tools, can autonomously edit itself, and thereby improve its performance on benchmark tasks. We find performance gains from 17% to 53% on a random subset of SWE Bench Verified.”

原文片段 2: SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering. / locator:5

“We evaluate SWE-agent on SWE-bench and HumanEvalFix, achieving state-of-the-art performance on both with a pass@1 rate of 12.5% and 87.7%, respectively, far exceeding the previous state-of-the-art achieved with non-interactive LMs.”

从原文片段中可以看到, [A] 只展示了一个自改进 coding agent 在 SWE-Bench Verified 上的性能提升, 且提升结果来自于一个随机子集; [E] 则展示了 SWE-agent 在两个特定 benchmark 上的性能优于既有非交互式 LM baselines, 但其量级来自特定 benchmark 和系统设置。Claim 将这些 evidence 中的“basic coding tools”和“SWE-agent”直接推广到“工具增强型”

直接对比与错误机制 Claim 将两个不同层级的证据合并成一个更强的总体结论: 一方面, [A] 只证明一个自改进 coding agent 在 SWE-Bench Verified 随机子集上从 17% 提升到 53%, 并未直接比较“工具增强 agent”这一类别与非交互式 prompting; 另一方面, [E] 证明 SWE-agent 在 SWE-bench/HumanEvalFix 上优于既有非交互式 LM baselines, 但其量级来自特定 benchmark 和系统设置。Claim 中“仓库级软件工程任务上显著优于”“差距可达数倍至近一个数量级”把局部结果推广为跨系统、跨任务的普遍结论, 支持范围强于原文。

可追溯附录 正文只列直接相关的小片段; 完整抽取片段见 `appendix/error_case_1_sources.txt`。

4.2 错误样例 2: 给引用原文补入未直接给出的 Pearson $r > 0.7$ 数值

错误类型: Unsupported numeric detail / over-specific citation

Claim: CLIP 视觉编码器是 MLLM 视觉缺陷的关键瓶颈—CLIP 在方向、计数、视角等 7/9 种基础视觉模式上存在系统性失效, 且这些缺陷显著传递至下游 MLLM (Pearson $r > 0.7$)。

引用位置: [D]§3.1::¶; §3.2::T1/[D]§3.3::¶2

原文片段 1: Eyes Wide Shut? Exploring the Visual Shortcomings of Multimodal LLMs. / locator:3.1

“Figure 5. Examples from MMVP-VLM. MMVP-VLM consists of image pairs across nine visual patterns. The examples in the figure are from EVA01 ViT-g-14 model, one of the largest CLIP models that also fails to choose the right image given the text description.”

原文片段 2: Eyes Wide Shut? Exploring the Visual Shortcomings of Multimodal LLMs. / Abstract

“We further evaluate various CLIP-based vision-and-language models and found a notable correlation between visual patterns that challenge CLIP models and those problematic for multimodal LLMs.”

直接对比与错误机制 原文片段确实说明 CLIP-based models 在九类视觉模式上存在系统性失败，并提出要研究 CLIP failure pattern 与 MLLM failure pattern 的相关性；摘要片段也只提到了存在“notable correlation”。但当前可见原文片段没有给出 Pearson $r > 0.7$ ，也没有把“关键瓶颈”表述成定量结论。因此属于数值过精和证据不足。

可追溯附录 正文只列直接相关的小片段；完整抽取片段见 `appendix/error_case_2_sources.txt`。

A 附录说明

以下附录给出五个 case 的完整输入 prompt 与完整输出 `output.raw.txt`。为保证编译稳定，输出中的 ANSI terminal color 控制符已去除，正文内容未改写。

B C1 R1 输入 prompt

你是一名科研助理。你需要完成一份科研报告，并在报告生成后使用 `refchecker` 对学术引用进行核查和修复。

本任务分为三个阶段。三个阶段必须在同一次最终回复中按顺序输出。

阶段 1: 生成未修复初稿 ORIGINAL_REPORT

你需要基于给定课题和论文材料撰写一份结构化研究笔记。

阶段 1 硬性规则

- 这一阶段不得调用 `refchecker` / `verify_citation`。
- 这一阶段生成的初稿视为 `frozen original`。进入阶段 2 后，不得回头改写 `ORIGINAL_REPORT`。
- 你必须阅读 `workspace` 中提供的 [A]、[B]、[C] 三篇 PDF。
- 你必须自行检索并获取三篇高度相关的开放获取论文，标记为 [D]、[E]、[F]。
- 最终报告只能引用 [A]-[F] 六篇论文。
- 第二部分每条结论必须有 [A]-[F] 出处标签和 CPS 位置标注。

课题

Tool-augmented LLM agents 是否能比纯 LLM prompting 更好地解决复杂编程任务？

提供的论文 PDF

PDF 文件位于当前 `profile workspace` 的：

```
```text
input_papers/case1/A Self-Improving Coding Agent.pdf
input_papers/case1/Trae Agent: An LLM-based Agent for Software Engineering with Test-time Scaling.pdf
input_papers/case1/LLM Agents Making Agent Tools.pdf
```
```

提供论文元信息：

[A] Robeyns, Szummer & Aitchison (2025). "A Self-Improving Coding Agent." arXiv:2504.15228.
[B] Gao, Tian et al. (2025). "Trae Agent: An LLM-based Agent for Software Engineering with Test-time Scaling." arXiv:2507.23370.
[C] Robeyns et al. (2025). "LLM Agents Making Agent Tools." arXiv:2502.11705.

自主检索要求

- 优先使用 `arXiv` 或其他开放获取平台。
- 优先选择 2024-2025 年论文。
- 选择与课题直接相关的论文，不要选择只主题沾边的论文。
- 在第三部分列出 [D]-[F] 的完整信息和检索策略。

```
### ORIGINAL_REPORT 格式

ORIGINAL_REPORT 必须包含以下三个部分，总计约 800 中文字：

#### 第一部分：总体评估

基于全部六篇论文，概括当前证据状况、共识/分歧、局限或 gap。

#### 第二部分：逐条结论

提取 5~8 条具体、可被证伪的结论。每条使用：

```text
- 结论陈述。
 出处：[A] §N.M::¶K / [B] §N.M::TK
...
```

所有引用位置必须遵守 citation-standard 的 CPS 格式。

#### 第三部分：引用论文清单

列出 [A]~[F] 六篇论文的完整元信息：

```text
- [Tag] 作者（年份）. " 标题." 发表刊物/预印本平台. 标识符. 检索词: {检索策略}
...
```

对于 [A]~[C], 检索词填写 `provided_pdf`。

---

## 阶段 2: REFCHECKER_REPAIR_LOG

你必须对 ORIGINAL_REPORT 中的 [A]~[F] 引用清单和关键 claim-citation pair 做核查。

### 必须使用的工具

- 对 [A]~[F] 六篇引用条目逐条调用 refchecker 的 `verify_citation`。
- 调用时尽量提供 title、authors、year、doi、arxiv_id、url。
- 如果某篇论文缺少 DOI 或 arXiv ID, 也要用 title/year/authors 调用。

### 核查边界

- refchecker 结果只判断引用元数据真实性和匹配度。
- 你还必须基于已阅读的 PDF/全文检查 claim 是否被引用位置支持。
- 如果 refchecker 未能确认某条引用, 不要编造; 在 repair log 中写 `uncertain`。

### REFCHECKER_REPAIR_LOG 格式

只输出 JSONL 代码块。每行一个 JSON 对象：

```jsonl
{"case_id":"C1","run_id":"R1","item_id":"ref_A","item_type":"reference_metadata","citation_tag":"A","tool_called_refchecker":"yes","refchecker_verified":"yes_or_no_or_uncertain","issue_type":"none_or_metadata"}
{"case_id":"C1","run_id":"R1","item_id":"claim_01","item_type":"claim_citation_pair","citation_tag":"A","tool_called_refchecker":"yes_or_no","refchecker_verified":"yes_or_no_or_uncertain","issue_type":"none"}
...
```

至少包含：

- 6 行 reference metadata 检查记录: `ref_A` 到 `ref_F`。
- 每条第二部分结论至少 1 行 claim-citation pair 检查记录。

---

## 阶段 3: 生成修复后报告 REPAIRED_REPORT

基于 REFCHECKER_REPAIR_LOG 修复 ORIGINAL_REPORT。

### 修复规则

- 如果引用元数据错误, 修正第三部分引用清单。
- 如果 claim 超出引用材料支持范围, 弱化 claim。
- 如果引用不能支持 claim, 替换为能支持的 [A]~[F] 引用; 如果没有可替代引用, 删除该 claim。
- 不要新增未经检查的强 claim。
- REPAIRED_REPORT 仍必须只引用 [A]~[F] 六篇论文。
- REPAIRED_REPORT 仍必须遵守 CPS 引用位置格式。

---

## 最终输出格式

最终回复必须严格按以下四个顶层标题输出：

# ORIGINAL_REPORT

{阶段 1 初稿}

# REFCHECKER_REPAIR_LOG

```jsonl
{阶段 2 JSONL}
...
```

# REPAIRED_REPORT
```

【阶段 3 修复后报告】

RUN_SUMMARY

```
```json
{"case_id": "C1", "run_id": "R1", "tool_called_refchecker": "yes_or_no", "num_references_checked": 0, "num_claim_pairs_checked": 0, "num_issues_found": 0, "num_revisions_made": 0}
```
```

除上述四个顶层标题外，不要输出额外解释。

C C1 R1 输出 output.raw.txt

[agents/tool-policy] tool policy removed 5 tool(s) via tools.profile (coding): agents_list, gateway, message, nodes, tts
Now I have all the refchecker results. Let me compile the full report with all three phases.

ORIGINAL_REPORT

第一部分：总体评估

基于 [A]–[F] 六篇论文，当前证据清晰表明：配备工具与自主改进能力的 LLM agent 在复杂编程任务上显著优于纯 prompting 基线。[A] 在 SWE-Bench Verified 随机子集上实现 17%~53% 的 Pass@1 提升，[B] 以 75.20% Pass@1 登顶 SWE-Bench Verified。这些结果共同揭示了一个关键洞见：工具辅助的 agent 在解决真实世界软件问题中具有显著优势。这一发现对于推动 AI 在软件工程领域的落地应用具有重要启示意义。共识在于：工具使用、集成推理、自动 agent 改进是提升编程任务表现的核心机制。分歧出现在 agent 复杂性是否必要——[F] 用极简三步流程在 SWE-Bench Lite 上取得 32.00% Pass@1，挑战了 agent 必须复杂的假设。[C] 展示 agent 可自主修复漏洞的能力，进一步验证了工具辅助的必要性。关键 gap 与局限：（1）自我改进在推理密集型任务上收效甚微（[A] §4.1）；（2）集成推理的计算成本与效果之间的最优平衡尚未解决（[B] §5.2）；（3）工具创建的规模化及跨领域泛化仍受限（[C] §6）；（4）所有方法均在特定 benchmark 上评估，泛化能力有待进一步验证。

第二部分：逐条结论

- 工具增强型 LLM agent 在仓库级软件工程任务上的表现远超纯 prompting 方法，SWE-Bench Verified 上的 Pass@1 可从 17% 提升至 53%。
出处：[A] §5::¶1; Abstract::¶1

- 基于 agent 的集成推理配合 patch 剪枝与选择机制，可进一步将 SWE-Bench Verified Pass@1 推至 75.20% 的顶尖水平，且性能随集成规模增大持续提升。
出处：[B] §6.1::¶1; §5.2::¶2; §5.2::¶10

- 自动搜索与迭代优化能发现超越人工设计的 agent 架构，在阅读理解、数学等任务上提升 F1 达 13.6 分、准确率达 14.4%。
出处：[D] §4.2::¶1; §4.2::¶1

- LLM agent 可自主将科研代码仓库转化为可复用的 LLM 兼容工具，在 15 项跨领域科学任务上实现 80% 成功率，远超现有软件工程 agent（OpenHands 仅 20%）。
出处：[C] §5::¶2; §5::¶1

- 复杂 agent 架构并非总是必要：仅使用定位-修复-验证三步流程的简单方法即可在 SWE-bench Lite 上实现 32.00% Pass@1，超过诸多复杂 agent 系统。
出处：[F] Abstract::¶1

- 专为 agent 设计的计算机界面显著提升 agent 的代码创建与编辑能力，证明交互界面设计对 agent 性能至关重要。
出处：[E] Abstract::¶1

- 自我改进 agent 在纯编码任务上提升显著，但在推理密集型任务（AIME、GPQA）上改进有限，揭示当前自我改进依赖于模型基础能力与 agent 框架的协同。
出处：[A] §4.1::¶2; §4.1::¶4

- 集成规模增大时，prompting-based 集成方法性能先升后降，而 agent-based 集成方法持续提升，表明模块化 agent 架构具有更好的可扩展性。
出处：[B] §5.2::¶10; §5.2::¶2

第三部分：引用论文清单

- [A] Robeyns, Szummer & Aitchison (2025). "A Self-Improving Coding Agent." arXiv 预印本. arXiv:2504.15228. 检索词: provided_pdf
- [B] Gao, Tian et al. (2025). "Trae Agent: An LLM-based Agent for Software Engineering with Test-time Scaling." arXiv 预印本. arXiv:2507.23370. 检索词: provided_pdf
- [C] Robeyns et al. (2025). "LLM Agents Making Agent Tools." arXiv 预印本. arXiv:2502.11705. 检索词: provided_pdf
- [D] Hu, Lu & Clune (2025). "Automated Design of Agentic Systems." ICLR 2025. arXiv:2408.08435. 检索词: {"query": "\"automated design\" \"agentic systems\" coding agent", "categories": ["cs.AI"], "date_from": "2024-01-01", "date_to": "2025-07-01", "limit": 10, "offset": 0, "sort": "relevance", "status": "all", "tags": []}
- [E] Yang, Jimenez, Wettig, Lieret, Yao, Narasimhan & Press (2024). "SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering." arXiv 预印本. arXiv:2405.15793. 检索词: {"query": "\"SWE-agent\"", "categories": ["cs.AI"], "date_from": "2024-01-01", "date_to": "2025-07-01", "limit": 10, "offset": 0, "sort": "relevance", "status": "all", "tags": []}
- [F] Xia, Deng, Dunn & Zhang (2025). "Agentless: Demystifying LLM-based Software Engineering Agents." arXiv 预印本. arXiv:2407.01489. 检索词: {"query": "\"agentless LLM software engineering demystifying automation\"", "categories": ["cs.AI"], "date_from": "2024-01-01", "date_to": "2025-07-01", "limit": 10, "offset": 0, "sort": "relevance", "status": "all", "tags": []}

REFChecker_REPAIR_LOG

```
```jsonl
{"case_id": "C1", "run_id": "R1", "item_id": "ref_A", "item_type": "reference_metadata", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "标题、作者"}
{"case_id": "C1", "run_id": "R1", "item_id": "ref_B", "item_type": "reference_metadata", "citation_tag": "B", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "metadata_error", "issue_summary": "引用格式错误"}
{"case_id": "C1", "run_id": "R1", "item_id": "ref_C", "item_type": "reference_metadata", "citation_tag": "C", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "metadata_error", "issue_summary": "引用格式错误"}
{"case_id": "C1", "run_id": "R1", "item_id": "ref_D", "item_type": "reference_metadata", "citation_tag": "D", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "metadata_error", "issue_summary": "引用格式错误"}
{"case_id": "C1", "run_id": "R1", "item_id": "ref_E", "item_type": "reference_metadata", "citation_tag": "E", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "metadata_error", "issue_summary": "引用格式错误"}
{"case_id": "C1", "run_id": "R1", "item_id": "ref_F", "item_type": "reference_metadata", "citation_tag": "F", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "metadata_error", "issue_summary": "引用格式错误"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_01", "item_type": "claim_citation_pair", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "17%-53%提升"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_02", "item_type": "claim_citation_pair", "citation_tag": "B", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "75.20% Pass@1"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_03", "item_type": "claim_citation_pair", "citation_tag": "D", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "F1提升"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_04", "item_type": "claim_citation_pair", "citation_tag": "C", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "80%成功率"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_05", "item_type": "claim_citation_pair", "citation_tag": "F", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "32.00% Pass@1"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_06", "item_type": "claim_citation_pair", "citation_tag": "E", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "Agent-C修复漏洞"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_07", "item_type": "claim_citation_pair", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "AIME和GPQA得分"}
{"case_id": "C1", "run_id": "R1", "item_id": "claim_08", "item_type": "claim_citation_pair", "citation_tag": "B", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "prompting基线"}
```
```

REPAIRED_REPORT

第一部分：总体评估

基于 [A]–[F] 六篇论文，当前证据清晰表明：配备工具与自主改进能力的 LLM agent 在复杂编程任务上显著优于纯 prompting 基线。[A] 在 SWE-Bench Verified 随机子集上实现 17%~53% 的 Pass@1 提升（[A] §5::¶1），[B] 以 75.20% Pass@1 登顶 SWE-Bench Verified。这些结果共同揭示了一个关键洞见：工具辅助的 agent 在解决真实世界软件问题中具有显著优势。这一发现对于推动 AI 在软件工程领域的落地应用具有重要启示意义。共识在于：工具使用、集成推理、自动 agent 改进是提升编程任务表现的核心机制。分歧出现在 agent 复杂性是否必要——[F] 用极简三步流程在 SWE-bench Lite 上取得 32.00% Pass@1，挑战了 agent 必须复杂的假设（[F] Abstract::¶1）。[C] 展示 agent 可自主修复漏洞的能力，进一步验证了工具辅助的必要性。关键 gap 与局限：（1）自我改进在推理密集型任务上收效甚微（[A] §4.1）；（2）集成推理的计算成本与效果之间的最优平衡尚未解决（[B] §5.2）；（3）工具创建的规模化及跨领域泛化仍受限（[C] §6）；（4）所有方法均在特定 benchmark 上评估，泛化能力有待进一步验证。

第二部分：逐条结论

- 工具增强型 LLM agent 在仓库级软件工程任务上的表现远超纯 prompting 方法，SWE-Bench Verified 上的 Pass@1 可从 17% 提升至 53%。
出处：[A] §5::¶1; Abstract::¶1
- 基于 agent 的集成推理配合 patch 剪枝与选择机制，可进一步将 SWE-Bench Verified Pass@1 推至 75.20% 的顶尖水平，且性能随集成规模增大持续提升。
出处：[B] §6.1::¶1; §5.2::¶2; §5.2::F10
- 自动搜索与迭代优化能发现超越人工设计的 agent 架构，在阅读理解、数学等任务上提升 F1 达 13.6 分、准确率达 14.4%。
出处：[D] §4.2::T1; §4.2::¶1
- LLM agent 可自主将科研代码仓库转化为可复用的 LLM 兼容工具，在 15 项跨领域科学任务上实现 80% 成功率，远超现有软件工程 agent（OpenHands 仅 20%）。
出处：[C] §5::T2; §5::¶1
- 复杂 agent 架构并非总是必要：仅使用定位-修复-验证三步流程的简单方法即可在 SWE-bench Lite 上实现 32.00% Pass@1，超过诸多复杂 agent 系统。
出处：[F] Abstract::¶1
- 专为 agent 设计的计算机界面显著提升 agent 的代码创建与编辑能力，证明交互界面设计对 agent 性能至关重要。
出处：[E] Abstract::¶1
- 自我改进 agent 在纯编码任务上提升显著，但在推理密集型任务（AIME、GPQA）上改进有限，揭示当前自我改进依赖于模型基础能力与 agent 框架的协同。
出处：[A] §4.1::¶2; §4.1::F4
- 集成规模增大时，prompting-based 集成方法性能先升后降，而 agent-based 集成方法持续提升，表明模块化 agent 架构具有更好的可扩展性。
出处：[B] §5.2::F10; §5.2::¶2

第三部分：引用论文清单

- [A] Robeyns, Szummer & Aitchison (2025). "A Self-Improving Coding Agent." arXiv 预印本. arXiv:2504.15228. 检索词: provided_pdf
- [B] Trae Research Team, Gao, Tian, Meng, Wang, Hu, Xiao, Liu, Zhang, Chen, Gao, Lin, Xiong, Peng & Liu (2025). "Trae Agent: An LLM-based Agent for Software Engineering with Test-time Scaling." arXiv 预印本
- [C] Wölflein, Ferber, Truhn, Arandjelović & Kather (2025). "LLM Agents Making Agent Tools." Annual Meeting of the Association for Computational Linguistics (ACL) 2025. arXiv:2502.11705. 检索词: provided_pdf
- [D] Hu, Lu & Clune (2024). "Automated Design of Agentic Systems." International Conference on Learning Representations (ICLR) 2025. arXiv:2408.08435. 检索词: {"query": "\"automated design\" \"agentic system\""}
- [E] Yang, Jimenez, Wettig, Lieret, Yao, Narasimhan & Press (2024). "SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering." Advances in Neural Information Processing Systems (NeurIPS) 2024. arXiv:2406.19742. 检索词: SWE-agent
- [F] Xia, Deng, Dunn & Zhang (2024). "Agentless: Demystifying LLM-based Software Engineering Agents." arXiv 预印本. arXiv:2407.01489. 检索词: {"query": "agentless LLM software engineering demystifying automation"}

RUN_SUMMARY

```
```json
{"case_id": "C1", "run_id": "R1", "tool_called_refchecker": "yes", "num_references_checked": 6, "num_claim_pairs_checked": 8, "num_issues_found": 5, "num_revisions_made": 5}
```
```

D C2 R1 输入 prompt

你是一名科研助理。你需要完成一份科研报告，并在报告生成后使用 refchecker 对学术引用进行核查和修复。

本任务分为三个阶段。三个阶段必须在同一次最终回复中按顺序输出。

阶段 1：生成未修复初稿 ORIGINAL_REPORT

你需要基于给定课题和论文材料撰写一份结构化研究笔记。

阶段 1 硬性规则

- 这一阶段不得调用 refchecker / verify_citation。
- 这一阶段生成的初稿视为 frozen original。进入阶段 2 后，不得回头改写 ORIGINAL_REPORT。
- 你必须阅读 workspace 中提供的 [A]、[B]、[C] 三篇 PDF。
- 你必须自行检索并获取三篇高度相关的开放获取论文，标记为 [D]、[E]、[F]。
- 最终报告只能引用 [A]-[F] 六篇论文。
- 第二部分每条结论必须有 [A]-[F] 出处标签和 CPS 位置标注。

课题

用合成数据训练 LLM 是否会导致模型性能退化 (model collapse)?

提供的论文 PDF

PDF 文件位于当前 profile workspace 的：

```
```text
input_papers/case2/Knowledge Collapse in LLMs_When Fluency Survives but Facts Fail under Recursive Synthetic Training.pdf
input_papers/case2/Escaping Collapse_The Strength of Weak Data for Large Language Model Training.pdf
input_papers/case2/Multi-modal Synthetic Data Training and Model Collapse.pdf
```
```

提供论文元信息：

- [A] Huang et al. (2025). "Knowledge Collapse in LLMs: When Fluency Survives but Facts Fail under Recursive Synthetic Training." arXiv:2509.04796.
- [B] Amin, Babakniya, Bie, Kong, Syed & Vassilvitskii (2025). "Escaping Collapse: The Strength of Weak Data for Large Language Model Training." NeurIPS 2025 / arXiv:2502.08924.
- [C] Hu, Rostami & Thomason (2025). "Multi-modal Synthetic Data Training and Model Collapse: Insights from VLMs and Diffusion Models." arXiv:2505.08803.

自主检索要求

- 优先使用 arXiv 或其他开放获取平台。
- 优先选择 2024-2025 年论文。
- 选择与课题直接相关的论文，不要选择只主题沾边的论文。
- 在第三部分列出 [D]-[F] 的完整信息和检索策略。

ORIGINAL_REPORT 格式

ORIGINAL_REPORT 必须包含以下三个部分，总计约 800 中文字：

```
#### 第一部分：总体评估

基于全部六篇论文，概括当前证据状况、共识/分歧、局限或 gap。

#### 第二部分：逐条结论

提取 5-8 条具体、可被证伪的结论。每条使用：

```text
- 结论陈述。
 出处：[A] $N.M.:$K / [B] $N.M.:TK
```

所有引用位置必须遵守 citation-standard 的 CPS 格式。

#### 第三部分：引用论文清单

列出 [A]-[F] 六篇论文的完整元信息：

```text
- [Tag] 作者（年份）. "标题." 发表刊物/预印本平台. 标识符. 检索词: {检索策略}
```

对于 [A]-[C], 检索词填写 `provided_pdf`。

---

## 阶段 2: REFCHECKER_REPAIR_LOG

你必须对 ORIGINAL_REPORT 中的 [A]-[F] 引用清单和关键 claim-citation pair 做核查。

### 必须使用的工具

- 对 [A]-[F] 六篇引用条目逐条调用 refchecker 的 `verify_citation`。
- 调用时尽量提供 title、authors、year、doi、arxiv_id、url。
- 如果某篇论文缺少 DOI 或 arXiv ID, 也要用 title/year/authors 调用。

### 核查边界

- refchecker 结果只判断引用元数据真实性和匹配度。
- 你还必须基于已阅读的 PDF/全文检查 claim 是否被引用位置支持。
- 如果 refchecker 未能确认某条引用, 不要编造; 在 repair log 中写 `uncertain`。

### REFCHECKER_REPAIR_LOG 格式

只输出 JSONL 代码块。每行一个 JSON 对象：

```jsonl
{"case_id":"C2","run_id":"R1","item_id":"ref_A","item_type":"reference_metadata","citation_tag":"A","tool_called_refchecker":"yes","refchecker_verified":"yes_or_no_or_uncertain","issue_type":"none_or_metadata_error","claim_id":"C2","run_id":"R1","item_id":"claim_01","item_type":"claim_citation_pair","citation_tag":"A","tool_called_refchecker":"yes_or_no","refchecker_verified":"yes_or_no_or_uncertain","issue_type":"none_or_metadata_error"}
```

至少包含：

- 6 行 reference metadata 检查记录：`ref_A` 到 `ref_F`。
- 每条第二部分结论至少 1 行 claim-citation pair 检查记录。

---

## 阶段 3: 生成修复后报告 REPAIRED_REPORT

基于 REFCHECKER_REPAIR_LOG 修复 ORIGINAL_REPORT。

### 修复规则

- 如果引用元数据错误, 修正第三部分引用清单。
- 如果 claim 超出引用材料支持范围, 弱化 claim。
- 如果引用不能支持 claim, 替换为能支持的 [A]-[F] 引用; 如果没有可替代引用, 删除该 claim。
- 不要新增未经检查的强 claim。
- REPAIRED_REPORT 仍必须只引用 [A]-[F] 六篇论文。
- REPAIRED_REPORT 仍必须遵守 CPS 引用位置格式。

---

## 最终输出格式

最终回复必须严格按以下四个顶层标题输出：

# ORIGINAL_REPORT

{阶段 1 初稿}

# REFCHECKER_REPAIR_LOG

```jsonl
{阶段 2 JSONL}
```

# REPAIRED_REPORT

{阶段 3 修复后报告}

# RUN_SUMMARY

```json
```

```
{"case_id": "C2", "run_id": "R1", "tool_called_refchecker": "yes_or_no", "num_references_checked": 0, "num_claim_pairs_checked": 0, "num_issues_found": 0, "num_revisions_made": 0}
...
```

除上述四个顶层标题外，不要输出额外解释。

## E C2 R1 输出 output.raw.txt

```
[agents/tool-policy] tool policy removed 5 tool(s) via tools.profile (coding): agents_list, gateway, message, nodes, tts
ORIGINAL_REPORT
```

## 第一部分：总体评估

基于六篇论文的证据，当前学术界对“合成数据训练是否导致模型性能退化”已有较为一致的基本认知：纯合成数据在 **replace** 模式下必然导致 **model collapse**，但通过数据累积（**accumulate**）、混合真实数据、引入外部弱标注信号等方法，coll

## 第二部分：逐条结论

- 在纯合成数据替换式（**replace**）训练下，语言模型、扩散模型和 VAE 均必然出现 **model collapse**，测试损失随世代单调上升。

出处：[D] §2.1:¶3 / [E] §3:¶2 / [F] §2.1:¶5

- 当合成数据与原始真实数据以累积方式（**accumulate**）混合时，即使真实数据占比趋于零，**model collapse** 仍可被避免，测试损失保持有界。

出处：[D] §2.1:¶3 / [D] §3:¶1

- 仅在合成数据上递归训练的统计语言模型会发生“完全塌缩”（**total collapse**），学到的条件分布以概率 1 收敛至某个 **Dirac** 分布，彻底丧失语言多样性。

出处：[E] §2.2:Definition 1 / [E] §3:¶3

- 基于事实类问答的 LLM 递归合成训练中，知识塌缩表现为三阶段：**Stage A** 知识保持期 → **Stage B** 准确度下降但表面流利度保持（“自信地犯错”） → **Stage C** 指令遵循能力崩塌。

出处：[A] §3:¶2-4

- 模型塌缩在 VLM 图像描述任务中的表现与纯文本 LLM 截然不同：生成文本的词汇量和困惑度上升（方差增大），而非减少。

出处：[C] §4.2:¶3 / [C] §4.3:¶1

- 增加解码预算（如扩散模型更多去噪步数、LLM 更多采样次数）可产生更鲁棒的合成数据，有效缓解 **model collapse**。

出处：[C] §4.5:¶1 / [B] §6:¶1

- 通过 **boosting** 式框架——结合模型生成的合成数据与弱标注器（>0 弱信号）的外部标签——可保证迭代训练收敛至最优 LLM。

出处：[B] §6:Theorem 5 / [B] §5:Algorithm 2

- 在固定计算预算的 **accumulate-subsample** 工作流下，模型性能退化速度介于 **replace**（最快）和 **accumulate**（最慢）之间，不会爆炸式崩塌。

出处：[F] §3:¶1-2

## 第三部分：引用论文清单

- [A] Keisha, Wu, Wang, Koshiyama & Treleaven (2025). "Knowledge Collapse in LLMs: When Fluency Survives but Facts Fail under Recursive Synthetic Training." NeurIPS 2025 Workshop on Evaluating the Evolving L  
- [B] Amin, Babakniya, Bie, Kong, Syed & Vassilvitskii (2025). "Escaping Collapse: The Strength of Weak Data for Large Language Model Training." NeurIPS 2025 / arXiv:2502.08924. 检索词: provided\_pdf  
- [C] Hu, Rostami & Thomason (2025). "Multi-modal Synthetic Data Training and Model Collapse: Insights from VLMs and Diffusion Models." arXiv:2505.08803. 检索词: provided\_pdf  
- [D] Gerstgrasser, Schaeffer, Dey, Rafailov, Sleight, Hughes, Korbak, Agrawal, Pai, Gromov, Roberts, Yang, Donoho & Koyejo (2024). "Is Model Collapse Inevitable? Breaking the Curse of Recursion by Accumulat  
- [E] Seddik, Chen, Hayou, Youssef & Debbah (2024). "How Bad is Training on Synthetic Data? A Statistical Analysis of Language Model Collapse." arXiv:2404.05090. 检索词: {arXiv: (model collapse) AND (statist  
- [F] Kazdan, Schaeffer, Dey, Gerstgrasser, Rafailov, Donoho & Koyejo (2024). "Collapse or Thrive? Perils and Promises of Synthetic Data in a Self-Generating World." arXiv:2410.16713. 检索词: {arXiv: "model

# REFChecker\_REPAIR\_LOG

```
```jsonl
```

```
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "ref_A",
  "item_type": "reference_metadata",
  "citation_tag": "A",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "no",
  "issue_type": "metadata_error",
  "issue_summary": " 引用元数据"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "ref_B",
  "item_type": "reference_metadata",
  "citation_tag": "B",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": " 引用元数据"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "ref_C",
  "item_type": "reference_metadata",
  "citation_tag": "C",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": " 引用元数据"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "ref_D",
  "item_type": "reference_metadata",
  "citation_tag": "D",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": " 引用元数据"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "ref_E",
  "item_type": "reference_metadata",
  "citation_tag": "E",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": " 引用元数据"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "ref_F",
  "item_type": "reference_metadata",
  "citation_tag": "F",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": " 引用元数据"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_01",
  "item_type": "claim_citation_pair",
  "citation_tag": "D",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_02",
  "item_type": "claim_citation_pair",
  "citation_tag": "D",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_03",
  "item_type": "claim_citation_pair",
  "citation_tag": "E",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_04",
  "item_type": "claim_citation_pair",
  "citation_tag": "A",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_05",
  "item_type": "claim_citation_pair",
  "citation_tag": "C",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_06",
  "item_type": "claim_citation_pair",
  "citation_tag": "C",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_07",
  "item_type": "claim_citation_pair",
  "citation_tag": "B",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
},
{
  "case_id": "C2",
  "run_id": "R1",
  "item_id": "claim_08",
  "item_type": "claim_citation_pair",
  "citation_tag": "F",
  "tool_called_refchecker": "yes",
  "refchecker_verified": "yes",
  "issue_type": "none",
  "issue_summary": "claim A"
}
...
```

REPAIRED_REPORT

第一部分：总体评估

基于六篇论文的证据，当前学术界对“合成数据训练是否导致模型性能退化”已有较为一致的基本认知：纯合成数据在 **replace** 模式下必然导致 **model collapse**，但通过数据累积（**accumulate**）、混合真实数据、引入外部弱标注信号等方法，coll

第二部分：逐条结论

- 在纯合成数据替换式（**replace**）训练下，语言模型、扩散模型和 VAE 均必然出现 **model collapse**，测试损失随世代单调上升。

出处：[D] §2.1:¶3 / [E] §3:¶2 / [F] §2.1:¶5

- 当合成数据与原始真实数据以累积方式（**accumulate**）混合时，即使真实数据占比趋于零，**model collapse** 仍可被避免，测试损失保持有界。

出处：[D] §2.1:¶3 / [D] §3:¶1

- 仅在合成数据上递归训练的统计语言模型会发生“完全塌缩”（**total collapse**），学到的条件分布以概率 1 收敛至某个 **Dirac** 分布，彻底丧失语言多样性。

出处：[E] §2.2:Definition 1 / [E] §3:¶3

- 基于事实类问答的 LLM 递归合成训练中，知识塌缩表现为三阶段：**Stage A** 知识保持期 → **Stage B** 准确度下降但表面流利度保持（“自信地犯错”） → **Stage C** 指令遵循能力崩塌。

出处：[A] §3:¶2-4

- 模型塌缩在 VLM 图像描述任务中的表现与纯文本 LLM 存在差异：生成文本的词汇量和困惑度在递归训练中上升（方差增大），与纯 LLM 中观察到的方差下降趋势不同。

出处：[C] §4.2:¶3 / [C] §4.3:¶1

```
- 增加解码预算（如扩散模型更多去噪步数、LLM 更多采样次数）可产生更鲁棒的合成数据，在一定程度上缓解 model collapse。
  出处：[C] §4.5::¶1 / [B] §6::¶1

- 通过 boosting 式框架——结合模型生成的合成数据与弱标注器（>0 弱信号）的外部标签——可保证迭代训练收敛至最优 LLM。
  出处：[B] §6::Theorem 5 / [B] §5::Algorithm 2

- 在固定计算预算的 accumulate-subsample 工作流下，模型性能退化速度介于 replace（最快）和 accumulate（最慢）之间，未出现爆炸式崩塌。
  出处：[F] §3::¶1-2

## 第三部分：引用论文清单

- [A] Keisha, Wu, Wang, Koshiyama & Treleaven (2025). "Knowledge Collapse in LLMs: When Fluency Survives but Facts Fail under Recursive Synthetic Training." NeurIPS 2025 Workshop on Evaluating the Evolving L
- [B] Amin, Babakniya, Bie, Kong, Syed & Vassilvitskii (2025). "Escaping Collapse: The Strength of Weak Data for Large Language Model Training." NeurIPS 2025 / arXiv:2502.08924. 检索词: provided_pdf
- [C] Hu, Rostami & Thomason (2025). "Multi-modal Synthetic Data Training and Model Collapse: Insights from VLMs and Diffusion Models." arXiv:2505.08803. 检索词: provided_pdf
- [D] Gerstgrasser, Schaeffer, Dey, Rafailov, Sleight, Hughes, Korbak, Agrawal, Pai, Gromov, Roberts, Yang, Donoho & Koyejo (2024). "Is Model Collapse Inevitable? Breaking the Curse of Recursion by Accumulat
- [E] Seddik, Chen, Hayou, Youssef & Debbah (2024). "How Bad is Training on Synthetic Data? A Statistical Analysis of Language Model Collapse." arXiv:2404.05090. 检索词: {arXiv: (model collapse) AND (statist
- [F] Kazdan, Schaeffer, Dey, Gerstgrasser, Rafailov, Donoho & Koyejo (2024). "Collapse or Thrive? Perils and Promises of Synthetic Data in a Self-Generating World." arXiv:2410.16713. 检索词: {arXiv: "model

# RUN_SUMMARY

```json
{"case_id": "C2", "run_id": "R1", "tool_called_refchecker": "yes", "num_references_checked": 6, "num_claim_pairs_checked": 8, "num_issues_found": 1, "num_revisions_made": 3}
```
```

F C3 R1 输入 prompt

你是一名科研助理。你需要完成一份科研报告，并在报告生成后使用 refchecker 对学术引用进行核查和修复。

本任务分为三个阶段。三个阶段必须在同一次最终回复中按顺序输出。

阶段 1: 生成未修复初稿 ORIGINAL_REPORT

你需要基于给定课题和论文材料撰写一份结构化研究笔记。

阶段 1 硬性规则

- 这一阶段不得调用 refchecker / verify_citation。
- 这一阶段生成的初稿视为 frozen original。进入阶段 2 后，不得回头改写 ORIGINAL_REPORT。
- 你必须阅读 workspace 中提供的 [A]、[B]、[C] 三篇 PDF。
- 你必须自行检索并获取三篇高度相关的开放获取论文，标记为 [D]、[E]、[F]。
- 最终报告只能引用 [A]-[F] 六篇论文。
- 第二部分每条结论必须有 [A]-[F] 出处标签和 CPS 位置标注。

课题

AI 能否可靠预测蛋白质-配体结合亲和力，从而替代昂贵的湿实验筛选？

提供的论文 PDF

PDF 文件位于当前 profile workspace 的：

```
```text
input_papers/case3/GEMS - Enhancing Generalizable Binding Affinity Prediction by Removing Data Leakage and Integrating Language Model Embeddings into Graph Neural Networks.pdf
input_papers/case3/From In Silico to In Vitro_Evaluating Molecule Generative Models for Hit Generation.pdf
input_papers/case3/Assessing the potential of deep learning for protein-ligand docking.pdf
```
```

提供论文元信息：

- [A] Graber et al. (2025). "GEMS — Enhancing Generalizable Binding Affinity Prediction by Removing Data Leakage." bioRxiv:2024.12.09.627482 / Nature Machine Intelligence.
- [B] Osman et al. (2025). "From In Silico to In Vitro: Evaluating Molecule Generative Models for Hit Generation." arXiv:2512.22031.
- [C] Morehead et al. (2025). "Deep Learning for Protein-Ligand Docking: Are We There Yet?" arXiv:2405.14108.

自主检索要求

- 优先使用 arXiv、bioRxiv 或其他开放获取平台。
- 优先选择 2024-2025 年论文。
- 选择与课题直接相关的论文，不要选择只主题沾边的论文。
- 在第三部分列出 [D]-[F] 的完整信息和检索策略。

ORIGINAL_REPORT 格式

ORIGINAL_REPORT 必须包含以下三个部分，总计约 800 中文字：

第一部分：总体评估

基于全部六篇论文，概括当前证据状况、共识/分歧、局限或 gap。

第二部分：逐条结论

提取 5-8 条具体、可被证伪的结论。每条使用：

```
```text
- 结论陈述。
 出处：[A] §N.M::¶K / [B] §N.M::TK
```
```

所有引用位置必须遵守 citation-standard 的 CPS 格式。

```
#### 第三部分：引用论文清单

列出 [A]-[F] 六篇论文的完整元信息：

```text
- [Tag] 作者 (年份). " 标题." 发表刊物/预印本平台. 标识符. 检索词: {检索策略}
- ...

对于 [A]-[C], 检索词填写 `provided_pdf`。

阶段 2: REFCHECKER_REPAIR_LOG

你必须对 ORIGINAL_REPORT 中的 [A]-[F] 引用清单和关键 claim-citation pair 做核查。

必须使用的工具

- 对 [A]-[F] 六篇引用条目逐条调用 refchecker 的 `verify_citation`。
- 调用时尽量提供 title、authors、year、doi、arxiv_id、url。
- 如果某篇论文缺少 DOI 或 arXiv ID, 也要用 title/year/authors 调用。

核查边界

- refchecker 结果只判断引用元数据真实性和匹配度。
- 你还必须基于已阅读的 PDF/全文检查 claim 是否被引用位置支持。
- 如果 refchecker 未能确认某条引用, 不要编造; 在 repair log 中写 `uncertain`。

REFCHECKER_REPAIR_LOG 格式

只输出 JSONL 代码块。每行一个 JSON 对象:

```jsonl
{"case_id": "C3", "run_id": "R1", "item_id": "ref_A", "item_type": "reference_metadata", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes_or_no_or_uncertain", "issue_type": "none_or_metadata_error"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_01", "item_type": "claim_citation_pair", "citation_tag": "A", "tool_called_refchecker": "yes_or_no", "refchecker_verified": "yes_or_no_or_uncertain", "issue_type": "none_or_metadata_error"},
...

至少包含:

- 6 行 reference metadata 检查记录: `ref_A` 到 `ref_F`。
- 每条第二部分结论至少 1 行 claim-citation pair 检查记录。

---

## 阶段 3: 生成修复后报告 REPAIRED_REPORT

基于 REFCHECKER_REPAIR_LOG 修复 ORIGINAL_REPORT。

### 修复规则

- 如果引用元数据错误, 修正第三部分引用清单。
- 如果 claim 超出引用材料支持范围, 弱化 claim。
- 如果引用不能支持 claim, 替换为能支持的 [A]-[F] 引用; 如果没有可替代引用, 删除该 claim。
- 不要新增未经检查的强 claim。
- REPAIRED_REPORT 仍必须只引用 [A]-[F] 六篇论文。
- REPAIRED_REPORT 仍必须遵守 CPS 引用位置格式。

---

## 最终输出格式

最终回复必须严格按以下四个顶层标题输出:

# ORIGINAL_REPORT

{阶段 1 初稿}

# REFCHECKER_REPAIR_LOG

```jsonl
{阶段 2 JSONL}
...

REPAIRED_REPORT

{阶段 3 修复后报告}

RUN_SUMMARY

```json
{"case_id": "C3", "run_id": "R1", "tool_called_refchecker": "yes_or_no", "num_references_checked": 0, "num_claim_pairs_checked": 0, "num_issues_found": 0, "num_revisions_made": 0}
...

除上述四个顶层标题外, 不要输出额外解释。
```

G C3 R1 输出 output.raw.txt

```
[agents/tool-policy] tool policy removed 5 tool(s) via tools.profile (coding): agents_list, gateway, message, nodes, tts
Now I have all refchecker results and paper content. Let me compile the complete output.

# ORIGINAL_REPORT
```

第一部分：总体评估

当前证据显示，AI 在蛋白质-配体结合亲和力和预测方面取得了显著进展，但距离可靠替代湿实验筛选仍有实质性差距。六篇论文共同勾勒出一个核心矛盾：深度学习方法在标准基准测试上表现优异，但泛化到全新靶点时性能急剧衰减。Graber 等人 [

第二部分：逐条结论

- 常用结合亲和力和基准数据集（如 PDBbind）存在严重的蛋白与配体层面数据泄露，导致许多深度学习模型在 CASF 等标准基准上的性能被人为高估。
出处：[A] §1::¶1；§4.1::¶1；§5::¶1 / [D] §2.2::¶ 末；§5::¶3 / [E] §1::¶3；§2::¶3
- 在消除数据泄露的清洁训练-测试划分（CleanSplit）上，结构更简单的模型（如 GEMS）可超越更复杂的模型（如 GenScore），揭示过往 SOTA 报告中的进展可能主要来自过拟合记忆而非真正的泛化能力。
出处：[A] §4.1::¶2；§4.1::T1；§5::¶2 / [E] §2::¶3；§4::¶3
- 当在严格的新靶点划分上评估时，当前最优评分函数的性能从 CASF 基准的 Pearson r 0.8 急剧下降至约 0.4-0.6 的水平，表明对全新靶点的泛化远未解决。
出处：[E] §1::¶1；§4::¶2；§4::T2 / [A] §5::¶3
- 深度学习共折叠方法在蛋白-配体对接上整体优于传统方法，但在处理新颖的蛋白-配体结合口袋时全部面临显著挑战，即便是最新的 AlphaFold 3 也无法为超过 50% 的 DockGen-E 复合物预测结构准确且化学有效的结合构象。
出处：[C] §3.1::¶1；§3.2::¶1；§4::¶1
- DL 方法的对接性能与其训练数据中蛋白-配体结合构象的相似性显著相关，表明当前模型在很大程度上依赖记忆见过的结合模式，而非学习普通的物理化学原理。
出处：[C] §3.5::¶ 末；§3.5::Extended Data F4 / [E] §4::¶2
- 在类 hit 分子生成任务上，自回归生成模型经过类 hit 数据微调后，可以生成化学有效、满足药物化学过滤标准且具有体外生物活性的化合物，其中一个 GSK-3 抑制剂 IC50 达 314±15.3 nM。
出处：[B] §3.1::¶1；§3.1::T1；§3.3::¶1；§3.3::F2
- 最新 AI 基础模型 Boltz-2 的结合亲和力和预测与物理基准 ESMACS 之间仅存在弱至中等相关性，且对 top-100 排名化合物的预测完全失去区分能力，缺乏先导化合物识别所需的能量分辨率。
出处：[F] §2.1.2::¶3；§2.1.2::F4；§2.2.2::¶1；§2.2.2::F7
- 当前生成模型和评分模型均面临化学特异性不足的困境：共折叠方法难以在结构精度与化学相互作用保真度之间取得平衡，而评分模型的预测值集中分布于极窄范围，无法有效区分 hit 与 decoy。
出处：[C] §3.1::¶1；§3.2::¶2；§4::¶2 / [F] §2.1.2::¶2；§2.1.2::F4 / [B] §4::¶2

第三部分：引用论文清单

- [A] Graber, David; Stockinger, Peter et al. (2025). "GEMS — Enhancing Generalizable Binding Affinity Prediction by Removing Data Leakage and Integrating Language Model Embeddings into Graph Neural Networks." *arXiv preprint arXiv:2501.12345*.
- [B] Osman, Nagham; Lembo, Vittorio; Bottegoni, Giovanni; Toni, Laura (2025). "From In Silico to In Vitro: Evaluating Molecule Generative Models for Hit Generation." *AI for Science Workshop, NeurIPS 2025*.
- [C] Morehead, Alex; Giri, Nabin; Liu, Jian; Neupane, Pawan; Cheng, Jianlin (2025). "Assessing the potential of deep learning for protein-ligand docking." *arXiv:2405.14108*. 检索词: provided_pdf
- [D] Liu, Xuefeng; Jiang, Songhao; Duan, Xiaotian et al. (2024). "Binding Affinity Prediction: From Conventional to Machine Learning-Based Approaches." *arXiv:2410.00709*. 检索词: arXiv search "binding affinity prediction"
- [E] Kopko, Jakub; Graber, David; Eyrilmez, Saltuk Mustafa; Mazurenko, Stanislav; Bednar, David; Sedlar, Jiri; Sivic, Josef (2025). "Generalization Beyond Benchmarks: Evaluating Learnable Protein-Ligand Docking Models." *arXiv preprint arXiv:2501.12345*.
- [F] Wan, Shunzhou; Zhang, Xibei; Xue, Xiao; Coveney, Peter V. (2026). "On the Reliability of AI Methods in Drug Discovery: Evaluation of Boltz-2 for Structure and Binding Affinity Prediction." *arXiv:2603.01234*.

REFChecker_REPAIR_LOG

```
```jsonl
{"case_id": "C3", "run_id": "R1", "item_id": "ref_A", "item_type": "reference_metadata", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "no", "issue_type": "metadata_error", "issue_summary": "元数据与引用不匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "ref_B", "item_type": "reference_metadata", "citation_tag": "B", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "元数据与引用匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "ref_C", "item_type": "reference_metadata", "citation_tag": "C", "tool_called_refchecker": "yes", "refchecker_verified": "no", "issue_type": "metadata_error", "issue_summary": "元数据与引用不匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "ref_D", "item_type": "reference_metadata", "citation_tag": "D", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "metadata_error", "issue_summary": "元数据与引用不匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "ref_E", "item_type": "reference_metadata", "citation_tag": "E", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "元数据与引用匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "ref_F", "item_type": "reference_metadata", "citation_tag": "F", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "元数据与引用匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_01", "item_type": "claim_citation_pair", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_02", "item_type": "claim_citation_pair", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_03", "item_type": "claim_citation_pair", "citation_tag": "E", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_04", "item_type": "claim_citation_pair", "citation_tag": "C", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_05", "item_type": "claim_citation_pair", "citation_tag": "C", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_06", "item_type": "claim_citation_pair", "citation_tag": "B", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_07", "item_type": "claim_citation_pair", "citation_tag": "F", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"},
{"case_id": "C3", "run_id": "R1", "item_id": "claim_08", "item_type": "claim_citation_pair", "citation_tag": "C", "tool_called_refchecker": "yes", "refchecker_verified": "yes", "issue_type": "none", "issue_summary": "claim 与 citation 匹配"}
```
```

REPAIRED_REPORT

第一部分：总体评估

当前证据显示，AI 在蛋白质-配体结合亲和力和预测方面取得了显著进展，但距离可靠替代湿实验筛选仍有实质性差距。六篇论文共同勾勒出一个核心矛盾：深度学习方法在标准基准测试上表现优异，但泛化到全新靶点时性能急剧衰减。Graber 等人 [

第二部分：逐条结论

- 常用结合亲和力和基准数据集（如 PDBbind）存在严重的蛋白与配体层面数据泄露，导致许多深度学习模型在 CASF 等标准基准上的性能被人为高估。
出处：[A] §1::¶1；§4.1::¶1；§5::¶1 / [D] §2.2::¶ 末；§5::¶3 / [E] §1::¶3；§2::¶3
- 在消除数据泄露的清洁训练-测试划分（CleanSplit）上，GEMS 模型可超越更复杂的模型（如 GenScore），提示过往 SOTA 报告中部分进展可能来自过拟合记忆而非真正的泛化能力。
出处：[A] §4.1::¶2；§4.1::T1；§5::¶2 / [E] §2::¶3；§4::¶3
- 当在严格的新靶点划分上评估时，当前最优评分函数的性能从 CASF 基准的 Pearson r 0.8 急剧下降至约 0.4-0.6 的水平，表明对全新靶点的泛化远未解决。
出处：[E] §1::¶1；§4::¶2；§4::T2 / [A] §5::¶3
- 深度学习共折叠方法在蛋白-配体对接上整体优于传统方法，但在处理新颖的蛋白-配体结合口袋时全部面临显著挑战，即便是最新的 AlphaFold 3 也无法为超过 50% 的 DockGen-E 复合物预测结构准确且化学有效的结合构象。
出处：[C] §3.1::¶1；§3.2::¶1；§4::¶1
- DL 方法的对接性能与其训练数据中蛋白-配体结合构象的相似性显著相关（p<0.05），表明当前模型在很大程度上依赖记忆见过的结合模式，而非学习普通的物理化学原理。
出处：[C] §3.5::¶ 末；§3.5::Extended Data F4 / [E] §4::¶2
- 在类 hit 分子生成任务上，自回归生成模型经过类 hit 数据微调后，可以生成化学有效、满足药物化学过滤标准且具有体外生物活性的化合物，其中一个 GSK-3 抑制剂 IC50 达 314±15.3 nM。
出处：[B] §3.1::¶1；§3.1::T1；§3.3::¶1；§3.3::F2
- 最新 AI 基础模型 Boltz-2 的结合亲和力和预测与物理基准 ESMACS 之间仅存在弱至中等相关性，且对 top-100 排名化合物的预测与物理计算结果无显著相关性，表明其缺乏先导化合物识别所需的能量分辨率。
出处：[F] §2.1.2::¶3；§2.1.2::F4；§2.2.2::¶1；§2.2.2::F7
- 当前生成模型和评分模型均面临化学特异性不足的困境：共折叠方法难以在结构精度与化学相互作用保真度之间取得平衡，而评分模型的预测值集中分布于极窄范围，难以有效区分 hit 与 decoy。
出处：[C] §3.1::¶1；§3.2::¶2；§4::¶2 / [F] §2.1.2::¶2；§2.1.2::F4 / [B] §4::¶2

```
## 第三部分：引用论文清单

- [A] Graber, David; Stockinger, Peter; Meyer, Fabian; Mishra, Siddhartha; Horn, Claus; Buller, R. (2025). "GEMS — Enhancing Generalizable Binding Affinity Prediction by Removing Data Leakage and Integration." AI for Science Workshop, NeurIPS 2025 /

- [B] Osman, Nagham; Lembo, Vittorio; Bottegoni, Giovanni; Toni, Laura (2025). "From In Silico to In Vitro: Evaluating Molecule Generative Models for Hit Generation." AI for Science Workshop, NeurIPS 2025 /

- [C] Morehead, Alex; Giri, Nabin; Liu, Jian; Neupane, Pawan; Cheng, Jianlin (2024). "Assessing the potential of deep learning for protein-ligand docking." arXiv:2405.14108. 检索词: provided_pdf

- [D] Liu, Xuefeng; Jiang, Songhao; Duan, Xiaotian; Vasan, Archit; Huang, Qinan; Liu, Chong; Li, Michelle M.; Ma, Heng; Brettin, Thomas; Ramanathan, Arvind; Xia, Fangfang; Wang, Mengdi; Pandey, Abhishek; Zit

- [E] Kopko, Jakub; Graber, David; Eyrilmez, Saltuk Mustafa; Mazurenko, Stanislav; Bednar, David; Sedlar, Jiri; Sivic, Josef (2025). "Generalization Beyond Benchmarks: Evaluating Learnable Protein-Ligand Scoring Models." arXiv:2503.01000. 检索词: provided_pdf

- [F] Wan, Shunzhou; Zhang, Xibei; Xue, Xiao; Coveney, Peter V. (2026). "On the Reliability of AI Methods in Drug Discovery: Evaluation of Boltz-2 for Structure and Binding Affinity Prediction." arXiv:2603.01000. 检索词: provided_pdf

# RUN_SUMMARY

```json
{"case_id": "C3", "run_id": "R1", "tool_called_refchecker": "yes", "num_references_checked": 6, "num_claim_pairs_checked": 8, "num_issues_found": 3, "num_revisions_made": 3}
```
```

H C4 R1 输入 prompt

你是一名科研助理。你需要完成一份科研报告，并在报告生成后使用 `refchecker` 对学术引用进行核查和修复。

本任务分为三个阶段。三个阶段必须在同一次最终回复中按顺序输出。

阶段 1: 生成未修复初稿 ORIGINAL_REPORT

你需要基于给定课题和论文材料撰写一份结构化研究笔记。

阶段 1 硬性规则

- 这一阶段不得调用 `refchecker` / `verify_citation`。
- 这一阶段生成的初稿视为 `frozen original`。进入阶段 2 后，不得回头改写 `ORIGINAL_REPORT`。
- 你必须阅读 `workspace` 中提供的 [A]、[B]、[C] 三篇 PDF。
- 你必须自行检索并获取三篇高度相关的开放获取论文，标记为 [D]、[E]、[F]。
- 最终报告只能引用 [A]-[F] 六篇论文。
- 第二部分每条结论必须有 [A]-[F] 出处标签和 CPS 位置标注。

课题

多模态大模型 (MLLM, 如 GPT-4V、Gemini) 是否具备了类似人类的视觉理解能力?

提供的论文 PDF

PDF 文件位于当前 `profile workspace` 的:

```
```text
input_papers/case4/MMPerspective.pdf
input_papers/case4/What's in Common_Multimodal Models Hallucinate When Reasoning Across Scenes.pdf
input_papers/case4/HumanCognitive Benchmarks Reveal Foundational.pdf
```
```

提供论文元信息:

- [A] Tang et al. (2025). "MMPerspective: Do MLLMs Understand Perspective? A Comprehensive Benchmark for Perspective Perception, Reasoning, and Robustness." arXiv:2505.20426.
[B] Ross et al. (2025). "What's in Common? Multimodal Models Hallucinate When Reasoning Across Scenes." arXiv:2511.03768.
[C] Huang et al. (2025). "VisFactor: Benchmarking Fundamental Visual Cognition in Multimodal Large Language Models." arXiv:2502.16435.

自主检索要求

- 优先使用 `arXiv` 或其他开放获取平台。
- 优先选择 2024-2025 年论文。
- 选择与课题直接相关的论文，不要选择只主题沾边的论文。
- 在第三部分列出 [D]-[F] 的完整信息和检索策略。

ORIGINAL_REPORT 格式

`ORIGINAL_REPORT` 必须包含以下三个部分，总计约 800 中文字:

第一部分: 总体评估

基于全部六篇论文，概括当前证据状况、共识/分歧、局限或 `gap`。

第二部分: 逐条结论

提取 5-8 条具体、可被证伪的结论。每条使用:

```
```text
- 结论陈述。
 出处: [A] $N.M.:$K / [B] $N.M.:$K
```
```

所有引用位置必须遵守 `citation-standard` 的 CPS 格式。

第三部分: 引用论文清单

列出 [A]-[F] 六篇论文的完整元信息:

```
```text
- [Tag] 作者 (年份). " 标题." 发表刊物/预印本平台. 标识符. 检索词: {检索策略}
```

对于 [A]-[C], 检索词填写 `provided_pdf`。

---

## 阶段 2: REFCHECKER_REPAIR_LOG

你必须对 ORIGINAL_REPORT 中的 [A]-[F] 引用清单和关键 claim-citation pair 做核查。

### 必须使用的工具

- 对 [A]-[F] 六篇引用条目逐条调用 refchecker 的 `verify_citation`。
- 调用时尽量提供 title、authors、year、doi、arxiv_id、url。
- 如果某篇论文缺少 DOI 或 arXiv ID, 也要用 title/year/authors 调用。

### 核查边界

- refchecker 结果只判断引用元数据真实性和匹配度。
- 你还必须基于已阅读的 PDF/全文检查 claim 是否被引用位置支持。
- 如果 refchecker 未能确认某条引用, 不要编造; 在 repair log 中写 `uncertain`。

### REFCHECKER_REPAIR_LOG 格式

只输出 JSONL 代码块。每行一个 JSON 对象:

```jsonl
{"case_id": "C4", "run_id": "R1", "item_id": "ref_A", "item_type": "reference_metadata", "citation_tag": "A", "tool_called_refchecker": "yes", "refchecker_verified": "yes_or_no_or_uncertain", "issue_type": "none_or_metadata_error", "claim_citation_pair": "A", "claim": "你在这里引用了 [A] 的结论", "citation": "[A] 的结论"}
{"case_id": "C4", "run_id": "R1", "item_id": "claim_01", "item_type": "claim_citation_pair", "citation_tag": "A", "tool_called_refchecker": "yes_or_no", "refchecker_verified": "yes_or_no_or_uncertain", "issue_type": "none_or_metadata_error", "claim_citation_pair": "A", "claim": "你在这里引用了 [A] 的结论", "citation": "[A] 的结论"}
```

至少包含:

- 6 行 reference metadata 检查记录: `ref_A` 到 `ref_F`。
- 每条第二部分结论至少 1 行 claim-citation pair 检查记录。

---

## 阶段 3: 生成修复后报告 REPAIRED_REPORT

基于 REFCHECKER_REPAIR_LOG 修复 ORIGINAL_REPORT。

### 修复规则

- 如果引用元数据错误, 修正第三部分引用清单。
- 如果 claim 超出引用材料支持范围, 弱化 claim。
- 如果引用不能支持 claim, 替换为能支持的 [A]-[F] 引用; 如果没有可替代引用, 删除该 claim。
- 不要新增未经检查的强 claim。
- REPAIRED_REPORT 仍必须只引用 [A]-[F] 六篇论文。
- REPAIRED_REPORT 仍必须遵守 CPS 引用位置格式。

---

## 最终输出格式

最终回复必须严格按以下四个顶层标题输出:

# ORIGINAL_REPORT

{阶段 1 初稿}

# REFCHECKER_REPAIR_LOG

```jsonl
{阶段 2 JSONL}
```

# REPAIRED_REPORT

{阶段 3 修复后报告}

# RUN_SUMMARY

```json
{"case_id": "C4", "run_id": "R1", "tool_called_refchecker": "yes_or_no", "num_references_checked": 0, "num_claim_pairs_checked": 0, "num_issues_found": 0, "num_revisions_made": 0}
```

除上述四个顶层标题外, 不要输出额外解释。
```

I C4 R1 输出 output.raw.txt

```
[agents/tool-policy] tool policy removed 5 tool(s) via tools.profile (coding): agents_list, gateway, message, nodes, tts
Now I have all refchecker results. Let me compile the full three-phase report.

# ORIGINAL_REPORT

## 第一部分: 总体评估
```


多模态大模型 (MLLM) 在多项视觉-语言基准上取得了瞩目成绩，但它们是否具备类似人类的视觉理解能力仍是开放问题。六篇论文的证据一致表明：当前最强 MLLM 在基本视觉感知任务上远逊于人类。Tang et al. [A] 发现 MLLM 在透视感知、推理

第二部分：逐条结论

- 当前顶级 MLLM (GPT-4V、Gemini) 在基础视觉感知任务上的表现远逊于人类，平均准确率低至 50% 左右，远低于人类 95% 以上的水平。
出处：[E] Abstract::¶1; §4.2::T1 / [D] §4::T1

- MLLM 在判断两条线是否相交、两个圆是否重叠等极简几何任务中频繁出错，尤其当图形间距缩小时性能急剧下降。
出处：[D] §4.1::¶2; §4.2::¶2

- 视觉编码器本身包含解决底层视觉任务的充分信息，瓶颈在于语言模型无法将这些视觉特征解码为正确回答。
出处：[D] §6::¶1; §3::¶3

- MLLM 在透视感知和推理任务中存在系统性缺陷，二维图像中的三维空间关系理解与人类差距显著。
出处：[A] §1::¶1

- MLLM 在跨场景推理（如识别多张图像间共有特征）时产生严重幻觉，倾向于捏造不存在的共性对象。
出处：[B] Abstract::¶1

- 从认知科学视角评估，MLLM 在视觉搜索、心理旋转等基础视觉认知任务上系统性落后于人类基准。
出处：[C] §1::¶1

- 视觉推理（而非文本推理）是 MLLM 的核心瓶颈：在 EMMA 基准上，52.83% 的错误源于视觉推理失败，包括三维空间模拟和多跳视觉推理。
出处：[F] §5.1::¶1; §5.1::¶2

- 测试时计算扩展（如多数投票、Best-of-N）和链式思维提示均无法实质性弥合 MLLM 与人类在视觉推理上的差距，最佳仅提升约 7 个百分点。
出处：[F] §4.3::¶1; §4.3::T3

第三部分：引用论文清单

- [A] Tang et al. (2025). "MMPerspective: Do MLLMs Understand Perspective? A Comprehensive Benchmark for Perspective Perception, Reasoning, and Robustness." arXiv preprint. arXiv:2505.20426. 检索词：`provided`
- [B] Ross et al. (2025). "What's in Common? Multimodal Models Hallucinate When Reasoning Across Scenes." arXiv preprint. arXiv:2511.03768. 检索词：`provided\_pdf`
- [C] Huang et al. (2025). "VisFactor: Benchmarking Fundamental Visual Cognition in Multimodal Large Language Models." arXiv preprint. arXiv:2502.16435. 检索词：`provided\_pdf`
- [D] Rahmanzadehgervi et al. (2024). "Vision Language Models are Blind: Failing to Translate Detailed Visual Features into Words." arXiv preprint. arXiv:2407.06581. 检索词：`VLMs are blind` visual perception
- [E] Fu et al. (2024). "BLINK: Multimodal Large Language Models Can See but Not Perceive." arXiv preprint. arXiv:2404.12390. 检索词：`BLINK multimodal large language models can see but not perceive Fu 2024`
- [F] Hao et al. (2025). "Can MLLMs Reason in Multimodality? EMMA: An Enhanced MultiModal ReAsoning Benchmark." arXiv preprint. arXiv:2501.05444. 检索词：`multimodal reasoning benchmark MLLM EMMA 2025`

REFChecker_REPAIR_LOG

```
```jsonl
{"case_id":"C4","run_id":"R1","item_id":"ref_A","item_type":"reference_metadata","citation_tag":"A","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" 元数据匹配"}
{"case_id":"C4","run_id":"R1","item_id":"ref_B","item_type":"reference_metadata","citation_tag":"B","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" 元数据匹配"}
{"case_id":"C4","run_id":"R1","item_id":"ref_C","item_type":"reference_metadata","citation_tag":"C","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"metadata_error","issue_summary":" "}
{"case_id":"C4","run_id":"R1","item_id":"ref_D","item_type":"reference_metadata","citation_tag":"D","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"metadata_error","issue_summary":" "}
{"case_id":"C4","run_id":"R1","item_id":"ref_E","item_type":"reference_metadata","citation_tag":"E","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"metadata_error","issue_summary":" "}
{"case_id":"C4","run_id":"R1","item_id":"ref_F","item_type":"reference_metadata","citation_tag":"F","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"metadata_error","issue_summary":" "}
{"case_id":"C4","run_id":"R1","item_id":"claim_01","item_type":"claim_citation_pair","citation_tag":"E","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [E] Abs"}
{"case_id":"C4","run_id":"R1","item_id":"claim_02","item_type":"claim_citation_pair","citation_tag":"D","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [D] §4"}
{"case_id":"C4","run_id":"R1","item_id":"claim_03","item_type":"claim_citation_pair","citation_tag":"D","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [D] §6"}
{"case_id":"C4","run_id":"R1","item_id":"claim_04","item_type":"claim_citation_pair","citation_tag":"A","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [A] §1"}
{"case_id":"C4","run_id":"R1","item_id":"claim_05","item_type":"claim_citation_pair","citation_tag":"B","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [B] Abs"}
{"case_id":"C4","run_id":"R1","item_id":"claim_06","item_type":"claim_citation_pair","citation_tag":"C","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [C] 论"}
{"case_id":"C4","run_id":"R1","item_id":"claim_07","item_type":"claim_citation_pair","citation_tag":"F","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [F] §5"}
{"case_id":"C4","run_id":"R1","item_id":"claim_08","item_type":"claim_citation_pair","citation_tag":"F","tool_called_refchecker":"yes","refchecker_verified":"yes","issue_type":"none","issue_summary":" [F] §4"}
...

```

# REPAIRED\_REPORT

## 第一部分：总体评估

多模态大模型 (MLLM) 在多项视觉-语言基准上取得了瞩目成绩，但它们是否具备类似人类的视觉理解能力仍是开放问题。六篇论文的证据一致表明：当前最强 MLLM 在基本视觉感知任务上远逊于人类。Tang et al. [A] 发现 MLLM 在透视感知、推理

## 第二部分：逐条结论

- 当前顶级 MLLM (GPT-4V、Gemini) 在基础视觉感知任务上的表现远逊于人类，平均准确率低至 50% 左右，远低于人类 95% 以上的水平。  
出处：[E] Abstract::¶1; §4.2::T1 / [D] §4::T1

- MLLM 在判断两条线是否相交、两个圆是否重叠等极简几何任务中频繁出错，尤其当图形间距缩小时性能急剧下降。  
出处：[D] §4.1::¶2; §4.2::¶2

- 视觉编码器本身包含解决底层视觉任务的充分信息，瓶颈在于语言模型无法将这些视觉特征解码为正确回答。  
出处：[D] §6::¶1; §3::¶3

- MLLM 在透视感知和推理任务中存在系统性缺陷，二维图像中的三维空间关系理解与人类差距显著。  
出处：[A] §1::¶1

- MLLM 在跨场景推理（如识别多张图像间共有特征）时产生严重幻觉，倾向于捏造不存在的共性对象。  
出处：[B] Abstract::¶1

- 从认知科学视角评估，MLLM 在视觉搜索、心理旋转等基础视觉认知任务上系统性落后于人类基准。  
出处：[C] §1::¶1

- 视觉推理（而非文本推理）是 MLLM 的核心瓶颈：在 EMMA 基准上，52.83% 的错误源于视觉推理失败，包括三维空间模拟和多跳视觉推理。  
出处：[F] §5.1::¶1; §5.1::¶2

- 测试时计算扩展（如多数投票、Best-of-N）和链式思维提示均无法实质性弥合 MLLM 与人类在视觉推理上的差距，最佳仅提升约 7 个百分点。  
出处：[F] §4.3::¶1; §4.3::T3

## 第三部分：引用论文清单

- [A] Tang et al. (2025). "MMPerspective: Do MLLMs Understand Perspective? A Comprehensive Benchmark for Perspective Perception, Reasoning, and Robustness." arXiv preprint. arXiv:2505.20426. 检索词：`provided`  
- [B] Ross et al. (2025). "What's in Common? Multimodal Models Hallucinate When Reasoning Across Scenes." arXiv preprint. arXiv:2511.03768. 检索词：`provided\_pdf`  
- [C] Huang et al. (2025). "Human Cognitive Benchmarks Reveal Foundational Visual Gaps in MLLMs." arXiv preprint. arXiv:2502.16435. 检索词：`provided\_pdf`  
- [D] Rahmanzadehgervi et al. (2024). "Vision Language Models are Blind: Failing to Translate Detailed Visual Features into Words." ACCV 2024. arXiv:2407.06581. 检索词：`VLMs are blind` visual perception  
- [E] Fu et al. (2024). "BLINK: Multimodal Large Language Models Can See but Not Perceive." ECCV 2024. arXiv:2404.12390. 检索词：`BLINK multimodal large language models can see but not perceive Fu 2024`

```
- [F] Hao et al. (2025). "Can MLLMs Reason in Multimodality? EMMA: An Enhanced MultiModal Reasoning Benchmark." ICML 2025. arXiv:2501.05444. 检索词: `multimodal reasoning benchmark MLLM EMMA 2025`

RUN_SUMMARY

```json
{"case_id": "C4", "run_id": "R1", "tool_called_refchecker": "yes", "num_references_checked": 6, "num_claim_pairs_checked": 8, "num_issues_found": 4, "num_revisions_made": 4}
```
```

## J C5 R2 输入 prompt

你是一名科研助理。你需要完成一份科研报告，并在报告生成后使用 `refchecker` 对学术引用进行核查和修复。

本任务分为三个阶段。三个阶段必须在同一次最终回复中按顺序输出。

---

### ## 阶段 1: 生成未修复初稿 ORIGINAL\_REPORT

你需要基于给定课题和论文材料撰写一份结构化研究笔记。

#### ### 阶段 1 硬性规则

- 这一阶段不得调用 `refchecker` / `verify_citation`。
- 这一阶段生成的初稿视为 `frozen original`。进入阶段 2 后，不得回头改写 `ORIGINAL_REPORT`。
- 你必须阅读 `workspace` 中提供的 [A]、[B]、[C] 三篇 PDF。
- 你必须自行检索并获取三篇高度相关的开放获取论文，标记为 [D]、[E]、[F]。
- 最终报告只能引用 [A]-[F] 六篇论文。
- 第二部分每条结论必须有 [A]-[F] 出处标签和 CPS 位置标注。

#### ### 课题

AI coding agents（如 Claude Code、Cursor、Devin）是否已经可以替代初级软件工程师？

#### ### 提供的论文 PDF

PDF 文件位于当前 `profile workspace` 的：

```
```text
input_papers/case5/Trae Agent.pdf
input_papers/case5/SWE-Bench Pro.pdf
input_papers/case5/Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity.pdf
```
```

提供论文元信息：

- [A] Gao, Tian et al. (2025). "Trae Agent: An LLM-based Agent for Software Engineering with Test-time Scaling." arXiv:2507.23370.  
[B] Deng et al. (2025). "SWE-Bench Pro: Can AI Agents Solve Long-Horizon Software Engineering Tasks?" arXiv:2509.16941.  
[C] Becker, Rush, Barnes & Rein (2025). "Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity." arXiv:2507.09089.

#### ### 自主检索要求

- 优先使用 `arXiv` 或其他开放获取平台。
- 优先选择 2024-2025 年论文。
- 选择与课题直接相关的论文，不要选择只主题沾边的论文。
- 在第三部分列出 [D]-[F] 的完整信息和检索策略。

#### ### ORIGINAL\_REPORT 格式

`ORIGINAL_REPORT` 必须包含以下三个部分，总计约 800 中文字：

##### #### 第一部分：总体评估

基于全部六篇论文，概括当前证据状况、共识/分歧、局限或 `gap`。

##### #### 第二部分：逐条结论

提取 5-8 条具体、可被证伪的结论。每条使用：

```
```text
- 结论陈述。
  出处：[A] $N.M.:$K / [B] $N.M.:TK
```
```

所有引用位置必须遵守 `citation-standard` 的 CPS 格式。

##### #### 第三部分：引用论文清单

列出 [A]-[F] 六篇论文的完整元信息：

```
```text
- [Tag] 作者 (年份). " 标题." 发表刊物/预印本平台. 标识符. 检索词: {检索策略}
```
```

对于 [A]-[C]，检索词填写 ``provided_pdf``。

---

### ## 阶段 2: REFChecker\_REPAIR\_LOG

你必须对 `ORIGINAL_REPORT` 中的 [A]-[F] 引用清单和关键 `claim-citation pair` 做核查。

```
必须使用的工具

- 对 [A]-[F] 六篇引用条目逐条调用 refchecker 的 `verify_citation`。
- 调用时尽量提供 title、authors、year、doi、arxiv_id、url。
- 如果某篇论文缺少 DOI 或 arXiv ID，也要用 title/year/authors 调用。

核查边界

- refchecker 结果只判断引用元数据真实性和匹配度。
- 你还必须基于已阅读的 PDF/全文检查 claim 是否被引用位置支持。
- 如果 refchecker 未能确认某条引用，不要编造；在 repair log 中写 `uncertain`。

REFCHECKER_REPAIR_LOG 格式

只输出 JSONL 代码块。每行一个 JSON 对象：

```jsonl
{"case_id":"C5","run_id":"R2","item_id":"ref_A","item_type":"reference_metadata","citation_tag":"A","tool_called_refchecker":"yes","refchecker_verified":"yes_or_no_or_uncertain","issue_type":"none_or_metadata_error","repair_log":"",...}
{"case_id":"C5","run_id":"R2","item_id":"claim_01","item_type":"claim_citation_pair","citation_tag":"A","tool_called_refchecker":"yes_or_no","refchecker_verified":"yes_or_no_or_uncertain","issue_type":"none_or_metadata_error","repair_log":"",...}
...

```

至少包含：

- 6 行 reference metadata 检查记录：`ref\_A` 到 `ref\_F`。
- 每条第二部分结论至少 1 行 claim-citation pair 检查记录。

阶段 3：生成修复后报告 REPAIRED_REPORT

基于 REFCHECKER_REPAIR_LOG 修复 ORIGINAL_REPORT。

修复规则

- 如果引用元数据错误，修正第三部分引用清单。
- 如果 claim 超出引用材料支持范围，弱化 claim。
- 如果引用不能支持 claim，替换为能支持的 [A]-[F] 引用；如果没有可替代引用，删除该 claim。
- 不要新增未经检查的强 claim。
- REPAIRED_REPORT 仍必须只引用 [A]-[F] 六篇论文。
- REPAIRED_REPORT 仍必须遵守 CPS 引用位置格式。

最终输出格式

最终回复必须严格按以下四个顶层标题输出：

```
# ORIGINAL_REPORT

{阶段 1 初稿}

# REFCHECKER_REPAIR_LOG

```jsonl
{阶段 2 JSONL}
...

REPAIRED_REPORT

{阶段 3 修复后报告}

RUN_SUMMARY

```json
{"case_id":"C5","run_id":"R2","tool_called_refchecker":"yes_or_no","num_references_checked":0,"num_claim_pairs_checked":0,"num_issues_found":0,"num_revisions_made":0}
...

```

除上述四个顶层标题外，不要输出额外解释。

K C5 R2 输出 output.raw.txt

```
[agents/tool-policy] tool policy removed 5 tool(s) via tools.profile (coding): agents_list, gateway, message, nodes, tts
# ORIGINAL_REPORT

## 第一部分：总体评估

当前证据呈现出两面性。在受控基准测试上，前沿 LLM Agent 已展示接近初级工程师的表现：Trae Agent 在 SWE-Bench Verified 上 Pass@1 达 75.20% [A]。然而，更具生态效度的评估揭示出实质性差距：SWE-Bench Pro 上最强模型仅 43.6% [B]。

## 第二部分：逐条结论

- 在受控基准 SWE-Bench Verified 上，前沿 LLM Agent 的 Pass@1 已达 75.20%，但该基准中包含大量仅需 1-2 行修改的简单任务，未必能代表真实工程工作。
  出处：[A] §4.1::¶1；§4.1::¶2 / [B] §1::¶2

- 在更具挑战性且抗污染的 SWE-Bench Pro 上，最强模型 Claude Sonnet 4.5 仅解决 43.6% 的公开集任务，商业集上 Opus 4.1 仅 17.8%，表明当前 Agent 距离处理复杂企业级工程任务仍有较大差距。
  出处：[B] §5::T1；§5::T2；§6.1::¶3

- 严格的随机对照试验发现，资深开源开发者在真实项目中使用 Cursor Pro 和 Claude Sonnet 等前沿 AI 工具时，任务完成时间反增 19%，开发者事前预测加速 24%，事后仍估计加速 20%，表明主观感知与实际效果存在系统性偏差。
  出处：[C] §1::¶3；§3.1::¶1；§3.1::¶2

- AI 工具显著改变了开发者的时间分配：使用 AI 时，主动编码和搜索/阅读信息的时间占比下降，而审阅 AI 输出、提示 AI 系统和等待 AI 生成的时间占比上升，形成了从“创建”到“验证”的工作重心转移。
  出处：[C] §3.2::¶1；§3.2::F6 / [F] §4.2::¶2
```

