

OpenClaw 科研 Agent 的引用一致性评测

实验架构、流程与工程经验

李佳蓓 马惠文 毛恺诚 陈思琪

2026 年 6 月

目录

1	项目概述	3
1.1	核心问题	3
1.2	被测系统	3
1.3	Agent 生成的科研报告结构	3
2	引用标准化: citation-standard skill	4
2.1	为什么需要	4
2.2	CPS 语法 (Citation Position Standard)	4
2.3	技能组成	4
3	完整 Prompt 示例与 Agent 回复	4
3.1	Prompt 模板 (阶段 1 核心部分)	4
3.2	Agent 回复示例 (摘要)	5
4	实验设计	7
4.1	五个 Case	7
4.2	三个实验	7
4.3	评测方法: citation_check 流水线	7
5	E1: arxiv MCP 工具验证	8
5.1	实验设计	8
5.2	贴合分数测试结果	8
5.3	关键发现	8
5.4	归因分析	8

6	E2: Refchecker Repair 效果	10
6.1	实验设计	10
6.2	总体结果	10
6.3	错误类型分布	11
6.4	错误类型漂移	11
6.5	Failure Case 实例	12
7	E3: Memory MVP	12
7.1	实验设计	12
7.2	Per-Run 错误计数	12
7.3	分错误类型	12
7.4	Memory vs Refchecker 对比	15
8	归因分析总结	15
8.1	改进方向	15
9	实验对比总表	15
10	工程问题与解决方案	15
10.1	对实验结论的影响	16
11	现场展示工具包	16

1 项目概述

1.1 核心问题


OpenClaw 搭建的科研 Agent 在生成科研报告时，是否会出现”引用与结论不一致”？这里的”不一致”指：

1. 报告中的结论看起来有引用支持；
2. 但实际检查引用材料后，发现材料不能充分支持该结论；
3. 严重时，引用材料甚至与结论相矛盾。

本项目不修改 Agent 内部代码，而是构造可复现的评测材料、运行脚本、日志和后续标注流程。

1.2 被测系统

固定技术栈：OpenClaw + DeepSeek V4 Pro + PDF skill + citation-standard skill + arxiv MCP + mcp-refchecker + Brave Search。



1.3 Agent 生成的科研报告结构

Agent 按要求生成三段式结构化报告，并通过四个固定 marker 分隔：

报告部分	输出 Marker
总体评估—概括证据状况、共识/分歧、局限	# ORIGINAL_REPORT (三段式，初稿)
逐条结论—5-8 条可证伪结论，带 CPS 出处	
引用论文清单—完整元信息 + 检索策略	
Refchecker 核查记录—逐条 JSONL	
修复后报告	# REPAIRED_REPORT
运行元数据	# RUN_SUMMARY

每条结论使用 CPS 格式标注出处：

- 结论陈述。

出处：[A] §4.1::\paragraph2; [B] §3::T1

2 引用标准化：citation-standard skill

2.1 为什么需要

如果引用写法不统一，后续人工标注和脚本检查都会变得不可复现。原始 prompt 中的位置格式存在以下模糊性：

- Abstract → 粒度太粗，Abstract 有多个段落
- 第 5 页第 3 段 → 计数规则不统一（从何处开始计为第 1 段?）
- §4.1 节 → 中英文混用，风格不一致
- limitations 部分 → 自由文本描述，无法被程序解析

2.2 CPS 语法 (Citation Position Standard)

封闭词汇表 + 固定语法，使每个 claim-citation pair 可被程序拆解：

- 文献标签：[A] ~ [F]
- Section：\S4.1 精确到小节
- 元素类型：::paragraph2、::T1（表格）、::F1（图）、::Eq（公式）
- 多位置用；分隔：[A] \S4.1::\paragraph2; \S4.1::T2

2.3 技能组成

1. SKILL.md (67 行) —Agent 运行时遵守的规则
2. references/cps-spec.md (143 行) —完整语法规则
3. scripts/validate.py (244 行) —合规检查脚本

3 完整 Prompt 示例与 Agent 回复

以下为 Case 5（AI coding agents 是否可替代初级软件工程师）的完整 prompt 模板和 Agent 实际输出摘要。

3.1 Prompt 模板 (阶段 1 核心部分)

你是一名科研助理。你需要完成一份科研报告，并在报告生成后使用 `refchecker` 对学术引用进行核查和修复。

阶段 1: 生成未修复初稿 ORIGINAL_REPORT

硬性规则

- 阶段 1 不得调用 `refchecker / verify_citation`。
- 你必须阅读 `workspace` 中提供的 [A]、[B]、[C] 三篇 PDF。
- 你必须自行检索并获取三篇高度相关的开放获取论文，标记为 [D]、[E]、[F]。
- 最终报告只能引用 [A]~[F] 六篇论文。
- 第二部分每条结论必须有 [A]~[F] 出处标签和 CPS 位置标注。

课题

AI coding agents (如 Claude Code、Cursor、Devin) 是否已经可以替代初级软件工程师？

提供的论文 PDF

[A] Gao, Tian et al. (2025). "Trae Agent." arXiv:2507.23370.

[B] Deng et al. (2025). "SWE-Bench Pro." arXiv:2509.16941.

[C] Becker et al. (2025). "Measuring the Impact of Early-2025 AI on Experienced Open-Source Developer Productivity." arXiv:2507.09089.

自主检索要求

- 优先使用 arXiv MCP 或其他开放获取平台。
- 优先选择 2024-2025 年论文。
- 选择与课题直接相关的论文。

ORIGINAL_REPORT 格式 (约 800 中文字)

第一部分：总体评估

第二部分：逐条结论 (5-8 条，每条带 CPS 出处)

第三部分：引用论文清单 ([A]~[F] 完整元信息 + 检索策略)

3.2 Agent 回复示例 (摘要)

ORIGINAL_REPORT

第一部分：总体评估

六篇论文从多维度审视了 AI coding agent 的能力边界。在受控基准上，

基于集成的 Agent (Trae Agent) 已达到 75.20% Pass@1; 但在难度更高的 SWE-Bench Pro 上, 最强模型仅 43.6% 解决率, 商业代码库更降至 17.8%。RCT 证据表明 AI 工具对有经验开发者的生产力影响高度依赖场景。

第二部分：逐条结论

- 结论 1: AI coding agent 在标准化 SWE 基准上已接近饱和, 但在复杂长周期任务上表现显著不足。SWE-Bench Pro 中最佳模型 Pass@1 低于 45%, 且多数任务需跨多文件修改上百行代码。
出处: [B] §1::¶3 / [B] §4::T1
- 结论 2: 针对经验丰富开源开发者的 RCT 发现, 使用 AI 工具后任务完成时间反而延长约 32%, 开发者需花费约 9% 时间审查和清理 AI 生成代码。
出处: [C] §3.1::¶1 / [C] §3.2::¶1
- 结论 3: 综合六篇论文, AI coding agent 目前是"有能力的辅助工具"而非"合格的独立工程师", 其在可替代初级工程师之前需跨越的鸿沟包括长周期任务可靠性、代码仓库全局理解、以及减少而非增加人类验证负担。
出处: [A] §5::¶1 / [B] §7::¶2 / [C] §5::¶3

[... 其余结论省略 ...]

第三部分：引用论文清单

- [A] Gao, Tian et al. (2025). "Trae Agent: An LLM-based Agent for Software Engineering with Test-time Scaling." arXiv:2507.23370.
检索词: provided_pdf

[... 其余论文清单省略 ...]

REFCHECKER_REPAIR_LOG

```
```jsonl
{"item_id":"ref_A","refchecker_verified":"yes","issue_type":"none",...}
{"item_id":"claim_01","refchecker_verified":"yes",
 "issue_type":"overclaim","issue_summary":"Claim uses 45% as max
Pass@1 but paper reports 43.6% for Claude Sonnet 4.5 — minor
numerical discrepancy.","repair_action":"correct_metadata"}
[...]
```

```

...

REPAIRED_REPORT
[... 修复后报告 ...]

RUN_SUMMARY
{"case_id":"C5","run_id":"1","num_references_checked":6,
 "num_claim_pairs_checked":8,"num_issues_found":3,
 "num_revisions_made":3}

```

## 4 实验设计

### 4.1 五个 Case

Case	主题方向
C1	工具增强 LLM agent 与复杂 coding task (SWE-Bench 等)
C2	递归合成数据、弱数据效应、model collapse
C3	蛋白-配体 docking、分子生成、binding affinity、benchmark leakage
C4	人类认知 benchmark、多模态推理、cross-scene hallucination
C5	AI coding tools、experienced developer productivity、SWE-Bench Pro

每个 case 固定提供 3 篇 PDF [A][B][C], Agent 自主检索 3 篇 [D][E][F]。五个 case 覆盖不同学科和证据形态。

### 4.2 三个实验

实验	条件	规模	状态
E1: arxiv MCP 工具验证	arxiv_on vs arxiv_off	5 cases × 2 cond. × 3 runs	✓
E2: Refchecker Repair	repair_no vs repair_yes	5 cases × 3 runs	✓
E3: Memory MVP	M0 (no memory) vs M1	5 cases × 2 passes	✓

### 4.3 评测方法: citation\_check 流水线

1. 人工定义错误分类体系 (四种互斥类型) 并编写 few-shot prompt
  2. build\_judge\_inputs.py 从报告中抽取 claim-citation pair 并构造 batch
  3. run\_deepseek\_judge.py 将 few-shot prompt + claim pair 送入 DeepSeek 批量判定
- 错误分类体系:

- **Overclaim**: 结论强于原文证据（扩大适用范围、加强断言强度）
- **Mis-citation**: 被引论文沾边但接不上（讨论另一对象/任务/指标）
- **Unsupported Claim**: 在被引论文中完全找不到支撑依据
- **Contradiction**: claim 与论文内容相反或冲突

## 5 E1: arxiv MCP 工具验证

### 5.1 实验设计

验证 arxiv MCP 是否提升论文检索的相关性与可验证性。5 cases  $\times$  2 conditions (arxiv\_on / arxiv\_off)  $\times$  3 runs。

### 5.2 贴合分数测试结果

评分方式: LLM as a Judge, 使用 0-4 五档贴合度评分。校准规则: 同领域最多 1-2 分; 3-4 分需明确相关且有实质贡献。

- 4 分: 主题核心贴合, 可直接作为选题核心支撑文献
- 3 分: 高度相关, 提供实质性贡献, 但不一定是最核心文献
- 2 分: 中度相关, 更偏背景、补充、侧证或局部视角
- 1 分: 弱相关, 共享关键词或处于相邻场景, 实际贡献较弱
- 0 分: 不相关, 基本不能为该选题提供有效贡献

### 5.3 关键发现

1. 当我们以“查找论文与选题的贴合程度”进行分数量化时, arxiv-MCP 的开关与贴合度并无显著相关性。
2. 大部分开启的情况下贴合程度得分反而略低于 off。
3. **Case 5 无论开关均显著低于其他 case**, 这是最值得关注的异常。

### 5.4 归因分析


#### 第一层: 为什么结果合理

arxiv-mcp 和 refchecker-mcp 的主要作用不是直接优化“和题目有多贴”, 而是优化“能不能找到真实论文、拿到更可靠的论文元数据、减少幻觉引用”。前者更偏真实 arXiv 检索与读论文, 后者更偏引用核验与元数据校对, 最多间接影响贴合度。工具增强提升的是检索真实性与可验证性, 而非主题贴合度上界。


#### 第二层: C5 的机制

C5 arxiv\_on 更容易选到的论文类别: 需求工程、安全风险、开发者感知/社会讨论、 workflow 影响、质量与复杂度影响。这些论文大多只拿 1-2 分 (/4), 符合校准规则






(a) arxiv\_on vs arxiv\_off 整体贴合分数对比



(b) 各 case 维度的贴合分数分布



(c) C5 的论文类别分布与低分原因分析

图 1: arxiv-MCP 贴合分数测试结果

中”同领域最多 1-2 分”的设定。LLM 判断它们更多在谈”软件开发中的 LLM 影响”，而非”替代初级工程师的能力边界”。这在一定程度上反映了 LLM 在界定相似度或贴合度方面的局限。

## 6 E2: Refchecker Repair 效果

### 6.1 实验设计

验证 mcp-refchecker 是否能帮助 Agent 发现并修复引用错误。5 cases  $\times$  3 runs, 每次输出 ORIGINAL\_REPORT 和 REPAIRED\_REPORT。

### 6.2 总体结果




图 2: Refchecker repair 效果：各 case 原始 vs 修复后的错误计数

表 1: Refchecker repair 效果汇总

Case	Original	Repaired	变化
C1	2.7 $\pm$ 1.5	2.0 $\pm$ 1.0	$\downarrow$ 0.7
C2	2.7 $\pm$ 1.2	3.0 $\pm$ 1.0	$\uparrow$ 0.3
C3	4.3 $\pm$ 2.3	4.3 $\pm$ 2.3	=
C4	1.7 $\pm$ 1.2	2.0 $\pm$ 1.0	$\uparrow$ 0.3
C5	3.0 $\pm$ 1.4	3.0 $\pm$ 2.8	=
<b>Total</b>	<b>40</b>	<b>40</b>	<b>0</b>

总错误量 40 → 40, repair 没有减少错误总量。只有 C1 有轻微改善。

### 6.3 错误类型分布




图 3: 错误类型 2×2 全景 (refchecker 实验)

### 6.4 错误类型漂移

20 个配对 claim 中, 7 个在 repair 后错误类型改变, 但总量不变:

表 2: Repair 后的错误类型变化

变化方向	次数	含义
Overclaim → Mis-citation	2	措辞弱化了, 但引用位置错了
Mis-citation → Overclaim	2	引用修对了, 但表述夸大了
Mis-citation → Unsupported Claim	1	引用修对后, 证据不足被暴露
Contradiction → Overclaim	1	矛盾消除了, 但变成了夸大
Unsupported Claim → Mis-citation	1	加了引用, 但引错了

## 6.5 Failure Case 实例

### Case A: Mis-citation——引用沾边但接不上

- C1: ”精心设计的 *agent-computer interface* 是将 *LLM* 转化为高效编码 *agent* 的关键，直接使用 *vanilla shell* 交互会导致性能大幅下降。” → 被引论文讨论的是另一个对象/任务，引用位置无法支撑该论断。
- C1: ”通过测试时计算扩展（含树搜索和 *LLM* 验证），*agent* 性能随计算投入持续提升。” → Agent 把 ensemble reasoning（并行采样 + 投票）和 tree search (MCTS) 两个不同研究方向拼接到同一篇论文上。被引论文 Trae Agent 使用并行生成 + 剪枝 + 选择，从未使用树搜索。

### Case B: Overclaim——结论强于原文证据

- C1: ”工具增强型 *LLM agent* 的 *Pass@1* 可从 17% 提升至 53%。” → 论文 (SICA, arXiv:2504.15228) 原文说的是”performance gains from 17% to 53% on a random subset of SWE-Bench Verified”。Agent 省略了”random subset” 限定，且把特定架构 (SICA) 的结论归因为”工具增强型 *LLM agent*” 整个类别。
- C5: ”AI 更适合辅助而非替代有经验的工程师。” → 原文仅有用户反馈分析，未设计对照实验支撑强因果结论。

### Case B: Contradiction——罕见但最严重

- C5: ”使用 *AI* 后任务时间延长约 32%。” → 原文部分数据指向效率提升，方向相反。这条 claim 在 repair 后变成 Overclaim——错误类型漂移的典型案列。

## 7 E3: Memory MVP

### 7.1 实验设计

验证 Agent 是否能从之前的 refchecker/repair 经验中学习。5 cases × 2 passes (P1 → P2)。M1 条件下 repair log 摘要写入 memory，下个 case 检索注入；M0 无 memory。

### 7.2 Per-Run 错误计数

### 7.3 分错误类型

- Overclaim: Run1 C1=1, C3=1; Run2 C5=2 最多
- Unsupported Claim: 100% 集中在 C3, 两 run 各 3 个
- Contradiction: 清零——两 run 均无此类型
- Mis-citation: 极少, Run1 C4=1, Run2 C5=1




图 4: Memory 实验 M1 逐 run 错误计数

表 3: Memory M1 逐 run 结果

Case	Run 1	Run 2
C1	1	1
C2	0	1
C3	4	3
C4	2	1
C5	0	3
Sum	7	9

表 4: Memory M0 vs M1 总览

	M0	M1	变化
Run1	11	7	↓ 36%
Run2	11	9	↓ 18%
Total	22	16	↓ 27%




图 5: Memory 实验 M1 分错误类型




图 6: Refchecker Repair vs Memory 效果对比

## 7.4 Memory vs Refchecker 对比

Memory 减少错误总量 27%，效果优于 refchecker repair (repair 总量不变)。

## 8 归因分析总结

表 5: 核心 Insight 总结

#	Insight	支撑实验
1	arxiv MCP 提升检索可验证性，不提升主题贴合度	E1
2	refchecker 做 Citation verification，不代替 Claim verification	E2
3	repair 是错误类型漂移，不是错误消除	E2
4	领域专业度越高，工具辅助越无效	E2 + E3
5	Memory 比 refchecker repair 更有效 ( $\downarrow 27\%$ vs $0\%$ )	E3
6	Memory 消除 Contradiction，但不解决 Unsupported Claim	E3
7	C3 (生化) 是三个实验的共识 hard case	E1 + E2 + E3
8	C1 (主流 CS) 从所有干预中获益最大	E2 + E3

### 8.1 改进方向

1. refchecker 之前加 source-grounded check: 先让 Agent 逐句核对引用是否真的包含支撑信息
2. 领域自适应策略: 高专业度 case (如 C3) 采用更保守的 claim 策略
3. repair 改为迭代循环: ”改写  $\rightarrow$  再核查  $\rightarrow$  再改写”, 目标消除而非转换
4. Memory 写入来源扩展到 claim-level feedback, 而不仅是 repair log

## 9 实验对比总表

## 10 工程问题与解决方案

本项目的难点不只在实验设计，也在于让一个多工具科研 Agent 评测真正可复现。实验过程中暴露出的很多问题都不是模型输出本身，而是工具链、网络、profile 隔离、引用材料组织方式和判定流水线之间的耦合。下面总结主要问题和对应处理方式。

表 6: 三个实验核心指标横向对比

维度	E1: arxiv MCP	E2: Refchecker	E3: Memory
错误总量变化	N/A	40 → 40 (=)	22 → 16 (↓27%)
C1 改善	N/A	↓ 0.7	↓ 最大
C3 改善	N/A	=	=
Contradiction	N/A	不变	<b>清零</b>
核心机制	检索真实性提升	元数据验证	经验迁移
主要局限	不提升 relevance	不验证语义支撑	领域知识鸿沟

## 10.1 对实验结论的影响

这些工程问题直接影响评测可信度。首先，工具预实验必须和主实验解耦，否则 arxiv MCP 的连接问题会被误解为 Agent 能力差异。其次，memory 实验必须按顺序执行，否则后续 case 的经验会提前污染前序 case。第三，最终 evaluator 不能依赖 Agent 自己的 refchecker repair log，因为这只是自我修复过程的一部分，而不是独立标注。最后，文献包必须按 pass 精确绑定，否则“引用与结论不一致”的错误率会混入材料组织错误。

因此，最终可复现材料不只包括报告输出，还包括 profile audit、run manifest、stderr、memory snapshot、pass-specific papers、claim-citation pair JSONL 和 judge batch prompt。这些文件共同构成了本实验的复现边界。

## 11 现场展示工具包

为现场展示准备的 demo 工具包位于 demo/ 目录：

```
demo/
 README.md -- 使用说明
 setup.sh -- 一键配置环境
 run.sh -- 运行入口（接受 --pdf 和 --topic）
 outputs/ -- 输出目录
```

使用方式：

```
bash demo/setup.sh # 首次配置
bash demo/run.sh --pdf paper.pdf --topic "... " # 运行
```

Agent 自动完成：读 PDF → 检索补充论文 → 生成 CPS 格式报告 → refchecker 核查 → 修复后报告。



表 7: 运行环境与工具链问题

问题	现象	处理方式
arXiv 网络访问不稳定	部分运行中 arXiv 域名被解析到异常地址, 或 web search / web fetch 长时间超时。	关闭 Clash Fake-IP 造成的虚拟网卡干扰; 对 OpenClaw 运行显式设置 HTTPS_PROXY、HTTP_PROXY 和 NO_PROXY, 将 arxiv.org / export.arxiv.org 放入直连列表, 保证 arXiv 直连、搜索服务走代理。
arxiv MCP 偶发 -32000 错误	MCP server 单独握手正常, 但 OpenClaw bundle-MCP 层有时无法稳定连接, 且并行运行会放大该问题。	将 arxiv MCP 作为预实验变量单独验证; 主实验中固定使用安全 wrapper 和 Brave Search fallback。运行脚本强制 JOBS=1, 避免多个 case 同时争用 MCP / web search。
多 profile 认证和工具配置漂移	新建 OpenClaw profile 后出现 DeepSeek API key 缺失、Brave plugin 未安装、memory/session search 被意外启用等问题。	为每个实验 profile 添加 profile audit; 统一 web search provider 为 Brave; 显式关闭与实验变量无关的 memory / session search; 把模型、thinking level、workspace 路径写入 manifest。
workspace 污染	不同 run 共用全局 workspace 时, 下载论文、临时文件和 memory 写回可能互相影响。	对预实验使用独立 profile / workspace; Memory MVP 只在 M1_memory_on 内按固定顺序共享 memory, 其它条件隔离。所有 prompt、raw output、manifest、stderr、memory snapshot 都落到 run 目录。
并行运行导致不稳定	JOBS=2 时 arXiv、web search、DeepSeek API 更容易 timeout, 且 memory 顺序语义被破坏。	所有 memory 相关主实验固定单线程顺序执行; 失败时使用新的 session_key suffix 重试, 并保留 run log 判断哪些输出是有效证据。

表 8: 评测材料与判定流水线问题

问题	现象	处理方式
引用格式不可解析	Agent 有时输出 <b>Abstract</b> 、第 5 页第 3 段或自由文本位置，无法稳定抽取 claim-citation pair。	新增 <code>citation-standard</code> skill，要求 CPS 格式：文献 tag、section、段落/图/表等元素类型全部显式化；同时提供 <code>validate.py</code> 做格式检查。
refchecker 不等于 claim verification	refchecker 可以校对论文元数据，但不能判断“这篇论文是否真的支撑这个结论”。Repair 后常出现错误类型漂移，而不是错误消除。	将 refchecker 定位为生成期辅助工具，而不是最终 evaluator；最终错误率另建 <code>citation_check</code> 流水线，由 claim-citation pair + 论文局部证据片段交给 judge 独立判定。
P1/P2 文献包不完全重合	同一个 case 中 P1 和 P2 可能把 [D]、[E] 指向不同论文；如果只在 <code>papers/</code> 中保存一份 [D].pdf，后续 judge 会读错证据。	将展示与评测材料整理到 <code>presentation/main_memory/</code> ；每个 pass 使用 pass-specific 文件名，例如 <code>P1_[D]_2405.17739.pdf</code> 与 <code>P2_[D]_2410.12944.md</code> ，脚本按 <code>case + pass + tag</code> 精确匹配。
LLM judge 成本和速度	如果每条 claim 都让模型完整阅读 PDF，API 慢且成本高，长上下文也会降低判定稳定性。	采用 local parser + locator snippet extraction + batched judge：先本地抽取 claim-citation pair 和定位片段，再每批 5-6 条送 DeepSeek 判断。PDF 缺失时使用 arXiv markdown 缓存，缺证据时标为 <code>NeedMoreContext</code> 或 <code>Unverifiable</code> 。

**感谢阅读**